# B 语言源码分析

本轮版本提示（2026-10-27）：当前 Blink 已统一普通与计算函数，源 program 声明改为返回类型（无值为 void），parallel 仍显式；应用用 target(cpu, ...) / target(gpu, ...) 选择位置，GPU 同步返回与显式下载分开。纯接口.h不再需要空.b。本书仍解读下述固定历史版本，源码节选及原生记录保留原文；当前规范和能力状态见 Docs/BLanguage.md 与 Docs/Issues.md。

从一行算式到 CPU 与 GPU 的真实执行

## 写在前面

一门语言怎样把 value = value * 2.0 + 1.0 变成处理器真正执行的工作？

这件事并不是把几个英文单词换成机器指令。编译器先要认出句子的结构，分清数字和数据，判断每一处读取、写入是否成立，再把计算整理成适合不同处理器的形式。计算开始以后，还要有人准备内存、安排执行，并在最后一个使用者结束后释放资源。

本书沿着这条完整路径阅读 Blink 的实现。Blink 简称 B 语言，B 也寓意 Base。开源工程在 https://github.com/sgua83/Blink 。读者最好已经写过少量 B 程序；熟悉 C/C++ 会有帮助，不要求预先学过编译原理、汇编、Rust 或 Vulkan。

遇到必要知识，我们先用能手算的例子说明，再进入源码。例如，先看乘法为什么应先于加法组成语法树，再看解析函数；先理解“两个值还要同时用，所以不能占同一个寄存器”，再看寄存器分配；先区分“工作已提交”和“工作已完成”，再看 GPU 资源释放。

分析对象固定为 Blink P4 CL13062。书中的节选从这一已提交版本直接取得，保留原标识符；完整函数较长时只选取相邻的关键行，并注明位置。compiler/源码版本索引.json 保存完整文件的版本与 SHA256。正文的手算、伪代码和示意图都明确用于解释，不冒充原始实现。

这一版本已经具有自研前端、并行中间表示、Windows x64 后端、SPIR-V 后端，以及 CPU/Vulkan 执行框架。它尚未具备由 B 独立应用入口编译出可直接启动的完整可执行程序。本书解读已经存在的实现；独立应用、基础库和跨平台能力的缺口另见 Docs/Issues.md 的 C-010 至 C-016。




图 0-1：前端回答“这段程序是什么意思”，后端回答“怎样表达给处理器”，执行框架回答“怎样使它真实运行”。箭头经过的每个对象都将在正文展开。

## 阅读路线

第一部分从一个小程序开始，补齐内存、Rust 阅读方法、词法、语法和类型知识。第二部分讲独占访问、范围事实、中间表示、控制流与优化。第三部分进入 CPU 指令、调用约定、寄存器、线程和 SIMD。第四部分进入 GPU 执行模型、SPIR-V、Vulkan、分页、同步与资源寿命。最后通过归约、扫描、筛选、排序和块内协作，看清高级并行操作怎样落到两种硬件上，再阅读 DLL 与完整源码结构。

各章末尾的“自己走一遍”用于检查是否理解，并附解释。它们是阅读练习，不是需要安装或执行的额外测试工具。

# 第一章 从四个数走完整条路径

## 1.1 先认识要追踪的计算

我们使用工程已有的 sample/lessons/map.b。这里的 map 表示逐元素计算；lessons.map 是教学模块名，不是标准库函数。先读最短的 scale：

源码节选：sample/lessons/map.b:9，P4 CL13062。

```
program scale(inout dataset<f32> values) on compute {
    parallel (value in values) {
        value = value * 2.0 + 1.0;
    }
}
```

输入为 [1.0,2.0,3.0,4.0]，每个元素先乘二再加一，得到 [3.0,5.0,7.0,9.0]。四个结果互不依赖。计算第三项时，不需要等待第一项算完，也不需要知道第一项的结果。

对应的 C 写法可以是下面这样。变量名和计算保持一致，差别集中在循环表达上。

```
for (unsigned i = 0; i < count; ++i) {
    float value = values[i];
    value = value * 2.0f + 1.0f;
    values[i] = value;
}
```

C 循环描述一个接一个访问下标的过程，成熟 C/C++ 编译器在条件允许时也能自动向量化。B 的 parallel 直接声明每个实例拥有当前元素；具体分成几个 CPU 范围、怎样组成 SIMD 批次，或怎样安排 GPU 工作组，由后面的实现决定。不能把这种语义差别简化为“C 总是串行，B 总是更快”。

## 1.2 同一个例子为什么还有 seed 和 demo

源码节选：sample/lessons/map.b:1，P4 CL13062。

```
module lessons.map;

program seed(write dataset<f32> values) on compute {
    parallel (value in values) {
        value = f32(index() + 1);
    }
}
```

seed 把元素设为从一开始的数字，index() 是从零开始的当前位置。第零项写入一，第一项写入二。

源码节选：sample/lessons/map.b:15，P4 CL13062。

```
program demo(inout dataset<f32> values) on compute {
    seed(values);
    scale(values);
}
```

demo 先产生数据，再完成变换。因此不需要额外编写输入文件，就能得到这四个结果。源码有两个逐元素阶段，优化器可能把它们合成一个实际阶段。我们将在第十一章解释合并的条件。

## 1.3 下载、构建与观察

当前源码工具链在 Windows x64 上使用 Rust 和 Microsoft C++ 链接工具构建。安装 Rust stable 与 Visual Studio 的 C++ 桌面开发工具后，在 x64 Developer PowerShell 中执行：

```
git clone https://github.com/sgua83/Blink.git
cd Blink
cargo build --workspace --release
```

Rust 在这里编译的是 Blink 编译器和执行框架，B 算法仍由 Blink 自己的后端生成代码。GPU 执行还需要支持相应 Vulkan 能力的显卡与驱动。

先检查，再导出 CPU/GPU 代码：

```
.\target\release\blc.exe check sample\lessons\map.b sample demo
.\target\release\blc.exe build sample\lessons\map.b Saved\MapCode sample demo
```

这里的 `build` 输出可供研究的阶段代码与布局，尚不是应用 `.exe`。在这本源码分析书里，我们正要观察这些中间产物，因此会使用这一命令。

若要执行这个计算模块，使用现有模块运行器：

```
.\target\release\blrun.exe cpu sample\lessons\map.b demo sample Saved\MapCpu :4
.\target\release\blrun.exe gpu sample\lessons\map.b demo sample Saved\MapGpu :4
```

`:4` 申请四个初始为零的元素；`demo` 自己填入初值。结果保存在相应目录的 `values.bldata`。这属于当前执行工具的数据协议，不是 B 独立应用的最终使用方式。附录提供不加命令别名的直接读取方法。

本次实际输出节选：

```
program lessons.map::demo on Compute
source_stages=2, executable_stages=1
binding 0: InOut values : f32, stride=4
CPU values = [3.0, 5.0, 7.0, 9.0]
GPU values = [3.0, 5.0, 7.0, 9.0]
GPU AMD Radeon RX 9070 GRE
```

上面的阶段、布局和设备名来自工具输出；两行 values 从实际 BLDATA 读取后排成可读文本。启动和准备成本没有混入四元素算式的性能结论。




图 1-1：来自本书固定版本的 Release 构建与实际执行，显示数值和编译产物。四元素用于追踪实现，不承担性能比较任务。

## 1.4 从输入文字到输出数字

整条路径可以先压缩成一句话：读取 .h/.b，得到单词，组成语法树，检查类型与访问，建立并行阶段，做合法优化，生成 CPU 指令或 SPIR-V，再由执行框架准备资源并运行。

在这个过程中，“程序”至少有三种形态：编辑器里的文字、编译器内存中的结构、处理器消费的代码。它们描述同一件事，却不能彼此混淆。语法树不是机器码，机器码字节也不自动等于可执行文件。

自己走一遍。 若第二项结果不对，应先怀疑语法分析器吗？不应直接跳到某一层。先确认实际输入，再看编译出的操作与布局，最后核对 CPU/GPU 各自的结果。每一层都有自己的输入和输出，问题要沿着真实差异定位。

# 第二章 内存：数字怎样占据一段地址

## 2.1 先分清值、位和地址

值是一件事，保存值的位又是一件事。u32 的一和 f32 的一都占四字节，编码不同。f32 的 1.0 通常对应十六进制 3f800000，不能把这四字节当作无符号整数一使用。转换类型可能改变编码；逐位解释则保留编码，改变理解方式。

地址告诉我们数据在哪里。假设第一个 f32 的地址为一千，元素间隔为四字节，第四个元素位于 1000 + 3×4 = 1012。源码中的通用记录也是这个规律，只是间隔不一定等于单个字段的大小。

```
元素地址 = 数据起点 + 元素下标 × stride
字段地址 = 元素地址 + 字段偏移
```

这里的 stride 是相邻完整记录的间隔，字段偏移则描述字段在一条记录中的位置。理解这两个数，后面就能读懂 CPU 地址计算、GPU 分页、C ABI 和 view。

## 2.2 对齐为什么会产生空白

处理器和接口通常要求某些数据从适当的地址开始。对齐为十六意味着起点是十六的整数倍。一个 float3 有三个四字节分量，内容共十二字节；在此版本的 B 布局中，它的对齐是十六。单独作为数组元素时，记录间隔因而是十六，而非十二。

源码节选：crates/blanguage/src/ir.rs:79，P4 CL13062。

```
pub fn vector(s: Scalar, n: usize) -> Self {
    if n == 1 {
        return Self::scalar(s);
    }
    Self {
        name: format!(
            "{}{}",
            match s {
                Scalar::F32 => "float",
                Scalar::U32 => "uint",
                Scalar::I32 => "int",
                Scalar::Bool => "bool",
            },
            n
        ),
        arguments: Vec::new(),
        values: Vec::new(),
        size: n as u32 * 4,
        align: if n == 2 { 8 } else { 16 },
        components: (0..n).map(|i| (s, i as u32 * 4)).collect(),
        fields: Vec::new(),
        view: None,
        array: None,
    }
}
```

不要从“内容十二字节”推出“任何地方都连续十二字节”。记录中的字段、矩阵的行、整个 dataset 的 stride 都要按编译器布局处理。C++ 或 Rust 的同名类型也未必具有相同布局。




图 2-1：字段内容、对齐空白、完整记录间隔是三个不同概念。编译器给出统一布局，两个后端和执行框架共同消费。

## 2.3 源码中的 Ty 保存了什么

源码节选：crates/blanguage/src/ir.rs:18，P4 CL13062。

```
#[derive(Clone, Debug, PartialEq, Eq)]
pub struct Ty {
    pub name: String,
    pub arguments: Vec<Ty>,
    pub values: Vec<u32>,
    pub size: u32,
    pub align: u32,
    pub components: Vec<(Scalar, u32)>,
    pub fields: Vec<(String, u32, Box<Ty>)>,
    pub view: Option<Box<Ty>>,
    pub array: Option<Box<Ty>>,
}
```

size 是类型内容占用，align 是对齐，components 把值分解为标量及偏移，fields 保留记录字段。view 与 array 说明它是否还包含引用式只读资源或内联数组。

这样，一个 float3 在前端仍有完整类型，在后端却可拆成三个 f32 分量。语言向量不保证每一处都会使用一条硬件向量指令；是否批量执行，还取决于计算、访问和后端计划。

## 2.4 Dataset 是布局的实际承载者

源码节选：crates/blcompute/src/lib.rs:42，P4 CL13062。

```
pub struct Dataset {
    pub(crate) ty: Ty,
    pub(crate) stride: u32,
    pub(crate) count: u32,
    pub(crate) words: Vec<u32>,
    pub(crate) views: views::Views<ReadDataset>,
}
```

words 是 CPU 上的存储，count 是记录数，stride 是相邻记录间隔。这里使用 Vec<u32> 保存四字节 word，是保存原始位模式的容器，并不表示其中的所有字段都是 u32。

自己走一遍。 stride=32、字段偏移十二、下标三，字段距数组起点多远？3×32+12=108 字节。若把 stride 错当作字段大小四，读到的就会是另一条记录或另一个字段。

# 第三章 只学阅读源码所需的 Rust

## 3.1 结构体、枚举与 match

C 结构体保存字段，Rust 的 struct 也如此。Rust 的 enum 还可以让不同情况各自携带数据。例如中间指令 Constant 保存目标编号、标量类型和位模式；Binary 保存运算与两个输入。match 则逐种处理这些情况。

与“操作码加一堆随意字段”的写法相比，这种表示把哪些数据属于哪种情况直接写进类型。阅读时先看枚举有哪些分支，再寻找处理该分支的 match，就能沿着同一项能力贯穿前端和两个后端。

## 3.2 Option 和 Result 并不神秘

Option<T> 表示有或没有：Some(value) 保存内容，None 表示没有。阶段的 prefix: Option<PrefixCount> 表示阶段是否限制在某个有效前缀，不是把零当成“没有”。

Result<T,E> 表示成功或错误：Ok(value) 与 Err(error)。函数调用后面的 ? 表示成功就取出结果，失败就把错误交还上层。它不是重新尝试，也不是忽略错误。

源码节选：crates/blanguage/src/parser.rs:6，P4 CL13062。

```
pub fn parse(source: Source) -> Result<Module> {
    let tokens = lexer::lex(&source)?;
    Parser {
        source,
        tokens,
        at: 0,
    }
    .module()
}
```

读这段代码时，先把 lexer::lex(&source)? 译成“对源码分词；失败时结束当前解析并传递错误”。随后创建 Parser，从 token 零开始解析模块。暂时不必逐个研究 Rust 的借用语法。

## 3.3 引用、所有权和作用域

`&T` 表示只读借用，`&mut T` 表示独占可变借用。把值移动给另一个对象以后，旧变量通常不能再直接使用它。对象退出作用域会执行 `Drop`，类似 C++ 的析构。

这使资源拥有者可用类型表达，但不会自动替我们理解 GPU：CPU 函数返回时，设备工作可能还在执行。正确实现必须让拥有者保留到真实完成点。后文会看到，这恰恰是执行框架最重要的工作之一。

`Rc<T>` 让同一线程中的多个对象共享一个资源的所有权，复制 `Rc` 主要增加引用计数，不复制整个 GPU 缓冲。`Arc<T>` 使用原子引用计数，适合跨线程共享所有权。编译器的源码与定义用到 `Arc`；这个版本的 Vulkan 对象大量使用 `Rc`，不应因看到“共享”就一律理解为多线程安全。

## 3.4 unsafe 表示哪一层责任

机器码入口、原始指针和 Vulkan API 会出现 `unsafe`。它表示调用者必须满足 Rust 类型系统没有完整表达的条件，例如地址有效、布局正确、对象寿命足够。它不意味着“这一段不用讲清楚”，反而提示我们追问这些条件由谁建立。

自己走一遍。 `Rc<GpuDataset>` 被复制，显存内容会复制一份吗？不会。两个所有者引用同一实际对象。是否另有上传、读回或拷贝，要看执行路径，不能从 `Rc` 的 `clone` 推断。

# 第四章 模块装载：先把程序找齐

## 4.1 一个文件不等于整个程序

`map.h` 声明可公开使用的接口，`map.b` 给出实现。导入模块以后，编译器还要读取其接口与实现。只解析当前文件，却不知道调用的函数来自哪里，无法完成可靠的类型、访问与阶段分析。

入口在 `crates/blanguage/src/lib.rs`。公开接口 `compile` 编译入口模块，`compile_entry` 选择具体入口，`check` 允许只检查函数库，不要求伪造一个可执行计算 `program`。

源码节选：`crates/blanguage/src/lib.rs:128`，P4 CL13062。

```
pub fn compile(path: &Path, module_root: &Path) -> Result<Compilation> {
    compile_module(path, module_root, true, None)
}
/// 选择公开 program 的具体静态入口，例如 shade<13> 或 run<float3,17>。
pub fn compile_entry(path: &Path, module_root: &Path, entry: &str) -> Result<Compilation> {
    compile_module(path, module_root, true, Some(entry))
}
/// 库接口与完整导入闭包同样检查；无需为函数库伪造可执行 program。
pub fn check(path: &Path, module_root: &Path) -> Result<Compilation> {
    compile_module(path, module_root, false, None)
}
```

这些 API 接收文件路径与模块根目录。根目录用于把 `lessons.map` 这样的模块名映射到文件路径；它与 C 预处理器简单粘贴头文件的行为不同。

## 4.2 已装载和正在装载为什么不同

考虑 A 导入 B，B 又导入 A。装载 A 尚未完成，又从 B 回到 A，形成一个环。若只有“已经完成”列表，就发现不了正在递归的关系；若只标记见过，又可能把正常共享依赖误当成错误。

loaded 表示完成，visiting 表示当前递归路径。重复访问 completed 模块可以直接复用；回到 visiting 模块说明导入成环。这是深度优先遍历的一个实际应用。

源码节选：crates/blanguage/src/lib.rs:303，P4 CL13062。

```
let implementation = parser::parse(read(&path.with_extension("b"))?)?;
let interface = parser::parse(read(&path.with_extension("h"))?)?;
if implementation.name != interface.name {
    return implementation
        .source
        .fail(Span::default(), "B022", ".h 与 .b 的模块名不一致");
}
let name = implementation.name.clone();
if loaded.contains(&name) {
    return Ok(name);
}
world
    .sources
    .insert(name.clone(), implementation.source.clone());
if !visiting.insert(name.clone()) {
    return implementation.source.fail(
        Span::default(),
        "B023",
        "模块导入存在环；公共类型应移入共同依赖模块",
    );
}
```

两个集合只服务于装载过程，没有成为运行时的模块调度系统。

## 4.3 名字怎样变成唯一对象

不同模块都可以有 run，因此内部使用 模块::名称 区分它们。World 保存已读源码、记录类型、函数和类型集合。解析函数名时，还要结合当前模块、明确导入和公开权限，不能从整个世界里随意找一个同名函数。

.h/.b 的签名也要一致：名称相同还不够，参数类型、权限、参数名、执行目标和接口条件等都属于接口约定。否则调用者相信的接口与真正实现会是两回事。

自己走一遍。 A 与 B 都导入共同模块 C，C 会因此形成环吗？不会。C 完成后属于 loaded；只有沿尚未结束的递归路径回到原模块才是这里拒绝的循环。

# 第五章 词法：把一行字符切成能辨认的单元

## 5.1 为什么不能直接按空格切开

value=value*2.0+1.0; 没有空格，依然是完整语句。<= 是一个比较符，不能先吃掉 < 再把 = 留成另一项。小数点、范围 ..、名字里的下划线、行注释与块注释也各有意义。

词法分析逐段读取字符，产生 token。这个版本的 Token 保存两项：文本与位置。

源码节选：crates/blanguage/src/lexer.rs:3，P4 CL13062。

```
#[derive(Clone, Debug)]
pub struct Token {
    pub text: String,
    pub span: Span,
}
```

这里没有先把每个关键字编成独立枚举；解析器会比较 token 文本。这是当前实现的选择，不是所有编译器必须采用的做法。

## 5.2 一个扫描位置贯穿整个循环

at 是当前字节位置，start 是本次 token 的起点。空白和注释被跳过，普通标识符、数字、多字符运算符和单字符符号分别识别。最终切出 [start,at) 的原文。

源码节选：crates/blanguage/src/lexer.rs:59，P4 CL13062。

```
} else if let Some(op) = [
    "::", "..", "+=", "-=", "*=", "/=", "==", "!=", "<=", ">=", "&&", "||", "<<", ">>",
]
.iter()
.find(|op| bytes[at..].starts_with(op.as_bytes()))
{
    at += op.len();
```

多字符运算符优先于单字符符号，正是为了保留 <= 和 << 等整体。数字扫描允许指数写法的正负号，却不会把普通的加法号全部吞进数字。

对 value*2.0+1.0，逻辑上得到 value、*、2.0、+、1.0。词法层只确认形状，不负责判断 value 是否已声明、是否浮点数或能不能写入。

## 5.3 Span 是诊断通向原文的线

源码节选：crates/blanguage/src/ast.rs:3，P4 CL13062。

```
#[derive(Clone, Copy, Debug, Default)]
pub struct Span {
    pub start: usize,
    pub end: usize,
}
```

Span 的 start/end 是字节范围。错误显示时，再从源码求行号和字符列。因此中文注释的 UTF-8 字节数与人眼看到的字数不能直接混用。

本版标识符使用 ASCII，中文可写在注释里；字符串字面量与通用文本能力尚未完成。讲解实现时，应从 lexer 的实际分支得出结论，而非凭语言愿景补出一个不存在的 token。

自己走一遍。 a<=b 应得到三个 token 还是四个？三个：a、<=、b。a < = b 则不能因为外观相似就自动当成同一运算。

# 第六章 语法：算式为什么是一棵树

## 6.1 先用括号画出结构

value * 2.0 + 1.0 的结构是 (value * 2.0) + 1.0。根是加法，左边是乘法，乘法的左右两边才是 value 和常量二。若误组成 value * (2.0 + 1.0)，输入二时会从正确的五变成六。

语法树把这种关系保存下来。树中节点回答“做什么”，子节点回答“对什么做”。它比原始字符串更适合检查、重写和代码生成。

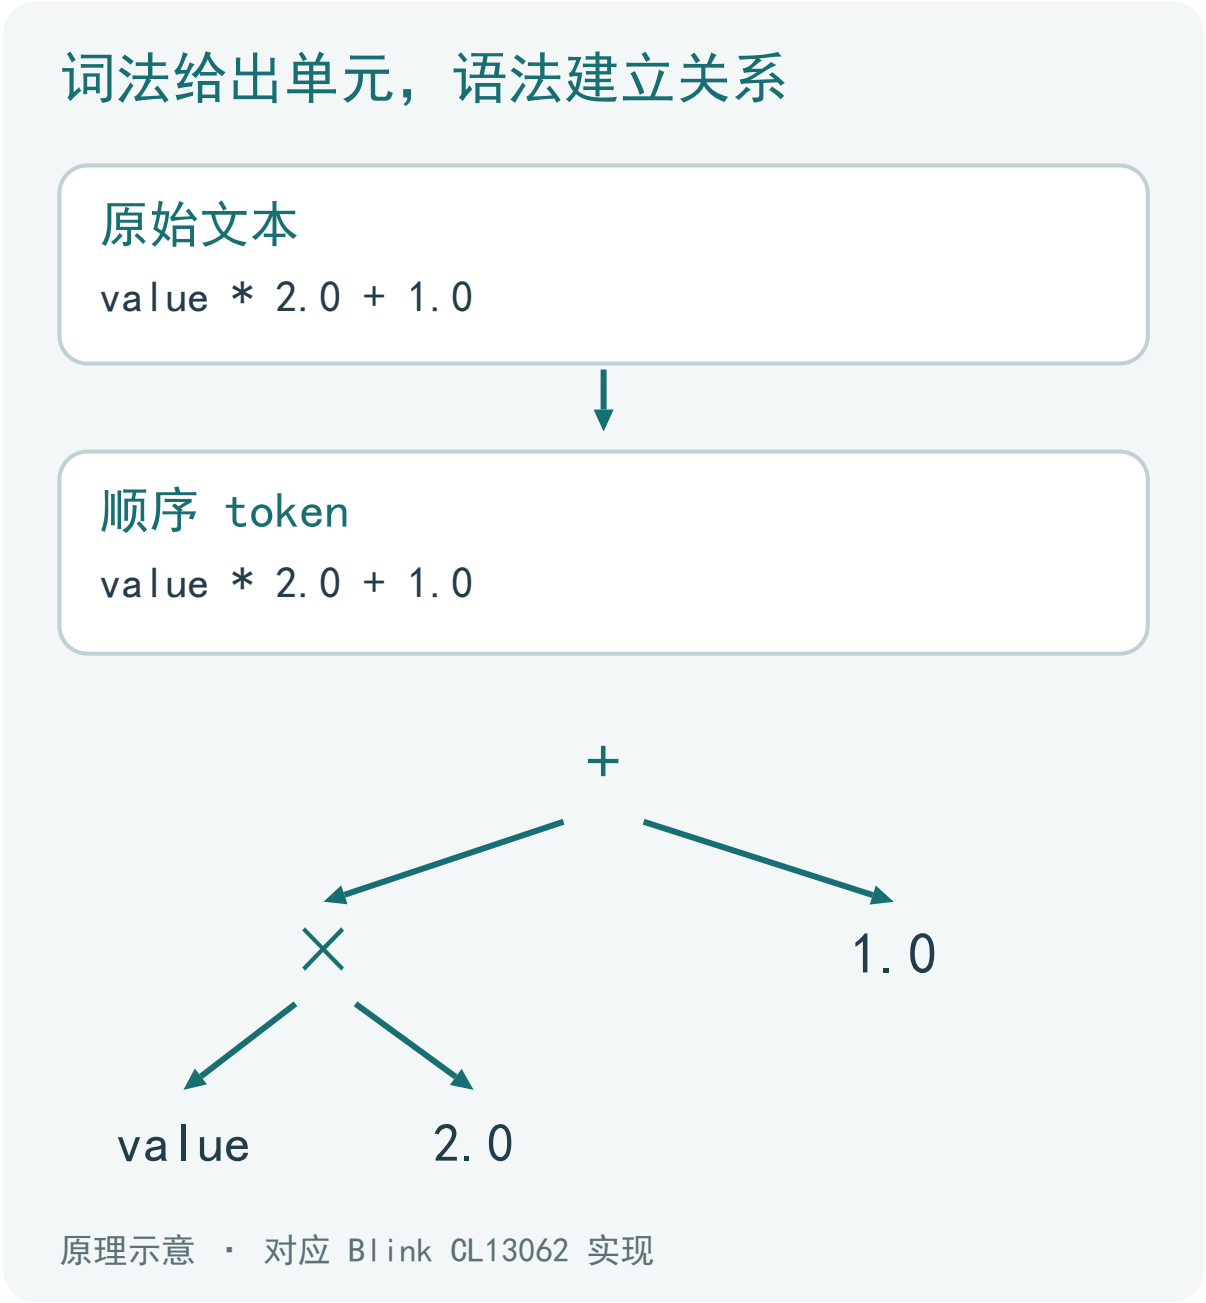



图 6-1：词法得到顺序单元，语法建立嵌套关系。树上的位置表示运算优先级，不表示硬件线程。

## 6.2 解析器怎样知道在哪里

源码节选：crates/blanguage/src/parser.rs:31，P4 CL13062。

```
struct Parser {
    source: Source,
    tokens: Vec<Token>,
    at: usize,
}
impl Parser {
    fn peek(&self) -> &str {
        &self.tokens[self.at].text
    }
    fn span(&self) -> Span {
        self.tokens[self.at].span
    }
    fn take(&mut self, text: &str) -> bool {
        if self.peek() == text {
```

```
            self.at += 1;
            true
        } else {
            false
        }
    }
```

peek 查看下一项，take 在匹配时向前移动，expect 则要求必须匹配，否则产生错误。读长解析函数时，始终记着“at 当前指向哪一个 token”，通常比盯着所有分支更容易理解。

## 6.3 优先级不是靠先写哪一行代码猜出来的

本版表达式使用带最低优先级参数的 expr。先解析一个基本表达式，再不断查看后续运算符。只有运算符优先级达到当前要求，才把它接入树中；右侧递归使用相应门槛，从而保持乘法先于加法等关系。

源码节选：crates/blanguage/src/parser.rs:852，P4 CL13062。

```
        let prec = match self.peek() {
            "||" => 1,
            "&&" => 2,
            "|" => 3,
            "^" => 4,
            "&" => 5,
            "==" | "!=" => 6,
            "<" | ">" | "<=" | ">=" => 7,
            "<<" | ">>" => 8,
            "+" | "-" => 9,
            "*" | "/" | "%" => 10,
            _ => 0,
        };
        if prec == 0 || prec < min {
            break;
        }
        let op = self.peek().to_owned();
        self.at += 1;
        let rhs = self.expr(prec + 1)?;
        lhs = Expr {
            kind: ExprKind::Binary(op, Box::new(lhs), Box::new(rhs)),
            span,
        };
    }
    Ok(lhs)
}
```

第一次阅读无需背下所有优先级数值。抓住两点：数值大小服务于结合次序，树形结构才是解析结果。括号则显式开启一个完整子表达式，读到右括号后再回到外层。

## 6.4 语句树保留了并行结构

普通算式之外，AST 还保存条件、循环、函数调用、parallel、阶段边界和集合操作的源形式。语法层知道这是并行语句，却还没有证明独占写入、有效下标或函数权限。结构合法和语义合法是两件事。

array<array<u32, 4>, 3> 中连续的 >> 在类型上下文是两个闭合尖括号；表达式中的 >> 则是右移。解析器的 type_close 专门区分这两个位置。同样的字符在不同语法位置可以承担不同意义。

自己走一遍。 2 + 3 * 4 的根是加法，右子树是乘法，结果十四。若代码生成器收到错误的树，后端再正确也只会忠实计算错误的结构。

# 第七章 类型与布局：不只检查能不能相加

## 7.1 名字到类型，还要经过解析

源文件里的 float3、用户记录和泛型参数先以 TypeName 保存。随后 World 结合模块和泛型实例，把它变成具有大小、对齐、分量和字段的 Ty。

这一步不仅拒绝不相容的加法，也决定一个字段究竟位于哪一字节。没有统一布局，CPU 后端、GPU 后端和调用方会对同一内存各有解释。

## 7.2 标量与记录怎样统一

源码节选：crates/blanguage/src/ir.rs:60，P4 CL13062。

```
pub fn scalar(s: Scalar) -> Self {
    Self {
        name: match s {
            Scalar::F32 => "f32",
            Scalar::U32 => "u32",
            Scalar::I32 => "i32",
            Scalar::Bool => "bool",
        }
        .into(),
        arguments: Vec::new(),
        values: Vec::new(),
        size: 4,
        align: 4,
        components: vec![(s, 0)],
        fields: Vec::new(),
        view: None,
        array: None,
    }
}
```

四种基本标量都用四字节存储，包含 bool。bool 在本版的内存布局里不是 C++ 的一字节 bool。一个记录被展开为多个带字节偏移的标量，字段保留名义结构。这样，通用代码生成可以逐分量处理，而不是为每个用户记录再写一套后端。

设记录包含 float3 position 和 f32 energy：position 的三个分量在偏移零、四、八；后续字段和最终 stride 按类型布局计算。不能把语言规则照搬成任意外部平台 C 结构体的默认布局，跨语言时使用生成接口更明确。

## 7.3 泛型：在编译期换成具体形状

“同一个函数能处理不同类型”有两种很不同的实现：运行时判断类型，或者编译前形成具体实例。Blink 当前主要采用后者。

源码节选：crates/blanguage/src/generics.rs:41，P4 CL13062。

```
let replacements: BTreeMap<_, _> = function
    .types
    .iter()
    .zip(arguments)
    .map(|(p, t)| (p.name.clone(), t))
    .collect();
let value_map: BTreeMap<_, _> = function
```

```
    .values
    .iter()
    .zip(values)
    .map(|(p, v)| (p.name.clone(), *v))
    .collect();
```

replacements 把类型参数映射到具体类型；value_map 把静态值参数映射到具体整数。随后替换函数签名、正文与条件，再进入原来的检查和代码生成路径。

例如一个宽度为四的固定数组与宽度为八的固定数组，存储、循环形状或协作工作量可能不同。把宽度在编译期确定，后端就能计算实际布局；代价是可能产生多个实例，编译量与代码体积也会增加。

## 7.4 泛型实例化不等于任意语言能力已经齐备

本版支持有限类型集合、具体类型和值参数、开放 u32 const 的具体实例等能力。一般关联类型、动态长度数组或所有符号约束不能因此推定为已完成。读 generics.rs、value_parameters.rs、type_sets.rs 时，应分别辨认“允许哪些实参”“怎样替换”“何时检查”。

自己走一遍。 把一个静态宽度从四改成八，需要修改 GPU 内存分配器里的固定字段偏移吗？不应如此。具体类型重新给出布局，后端与执行框架消费它，避免维护第二份权威布局。

# 第八章 并行的根基：每个实例到底拥有哪一个位置

## 8.1 数据竞争是什么

假设两个线程同时执行 total = total + 1。它们可能都先读到零，再各自写回一，最终只加了一次。问题不在加法本身，而在多个执行者同时读写同一位置，并且缺少足够的同步语义。

逐元素变换可以从更简单的所有权开始：实例零只改元素零，实例一只改元素一。它们对不同地址写入，既无需为每个元素加锁，也不依赖操作系统恰好按顺序调度。

## 8.2 read、write、inout 和 atomic 表达不同关系

源码节选：crates/blanguage/src/ast.rs:54，P4 CL13062。

```
#[derive(Clone, Copy, Debug, PartialEq, Eq)]
pub enum Access {
    Value,
    Read,
    Write,
    InOut,
    Atomic,
}
impl Access {
    pub fn reads(self) -> bool {
        matches!(self, Self::Read | Self::InOut | Self::Atomic)
    }
    pub fn writes(self) -> bool {
        matches!(self, Self::Write | Self::InOut | Self::Atomic)
    }
}
```

read 允许读取而不修改，write 表达输出，inout 读取并更新当前独占内容，atomic 允许通过原子操作共享访问。权限进入检查和依赖分析，不只是供文档阅读的注释。

原子操作能让某次访问不可分割，但不会自动消除算法顺序依赖；独占访问则从一开始避免多个实例争用同一输出位置。选择哪一种，取决于真实数据关系。

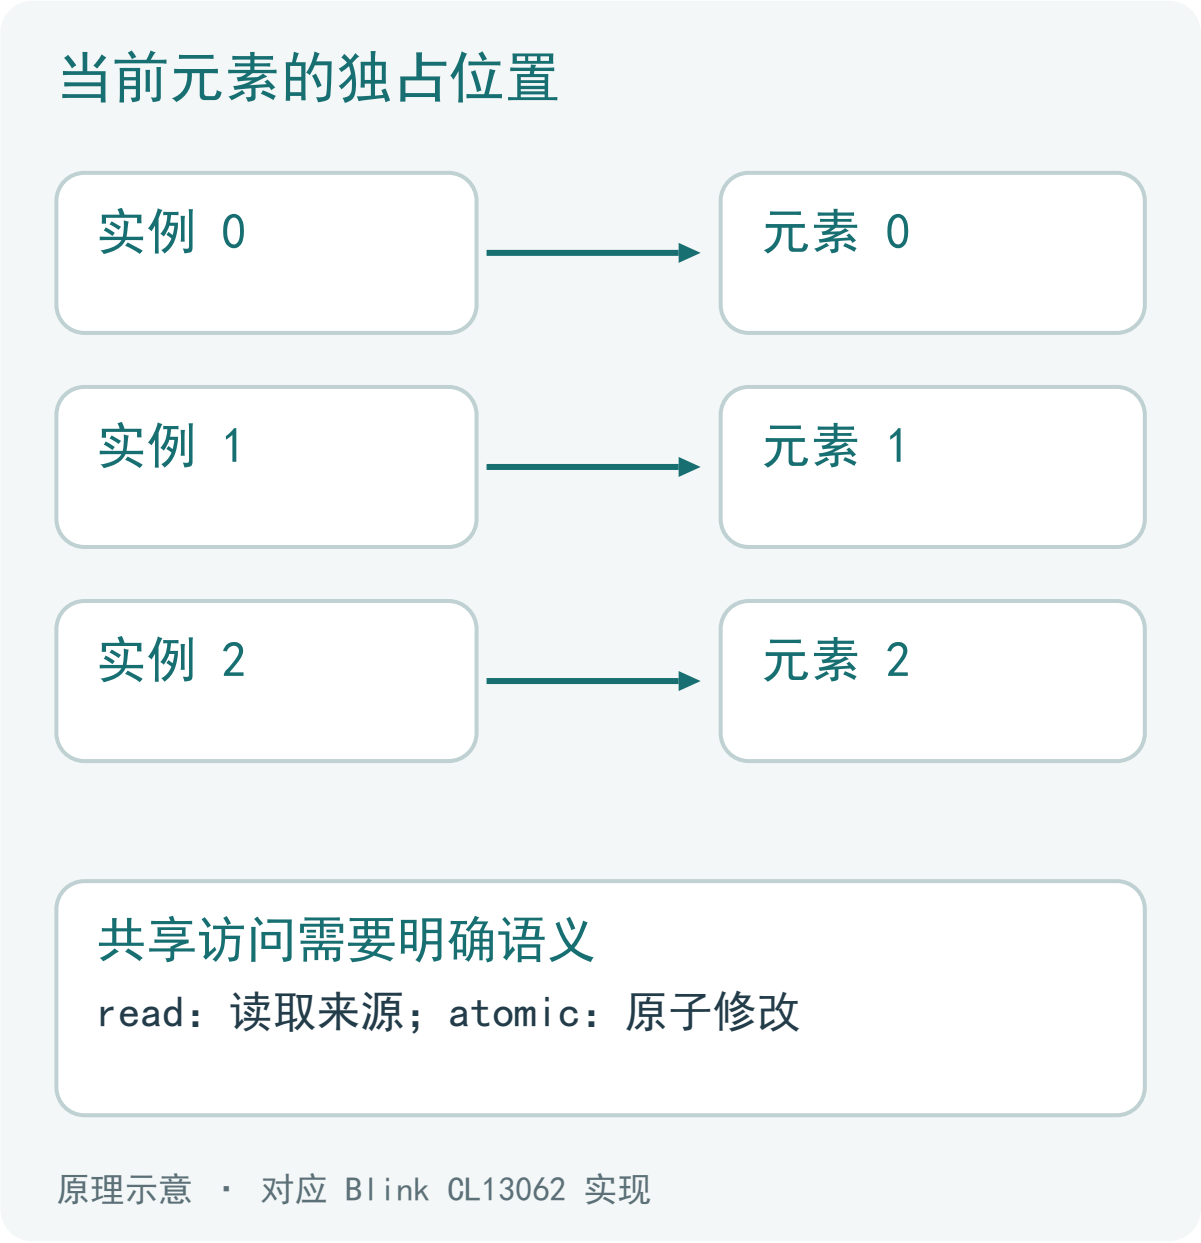



图 8-1：普通并行写沿当前元素的身份分开。读取其他元素需要合法只读来源；共享修改必须具有相应原子语义。

## 8.3 检查器同时问两个问题

源码节选：crates/blanguage/src/check.rs:2797，P4 CL13062。

```
    let binding = view.binding;
    let i = self.expr(index)?;
    self.require_same(&Ty::scalar(Scalar::U32), &i.ty, index.span)?;
    if !self.index_in(
        &i,
        IndexDomain::Data(binding),
        self.program.buffers[binding].count.unwrap_or(0),
    ) && !(binding == self.domain && i.regs[0] == self.global_index)
    {
        return self.fail(
            index.span,
```

```
            "B137",
            "索引有效性无法静态证明；使用有界游标、同域 index()、有效长度条件或形状约束",
        );
    }
    if self.view_access[&binding] != Access::Atomic
        && self.view_access[&binding].writes()
        && (binding != self.domain || i.regs[0] != self.global_index)
    {
        return self.fail(
            index.span,
            "B166",
            "并行可写数据只允许访问当前独占元素；读取其他元素需要独立 read 数据集",
        );
    }
    let ty = self.program.buffers[binding].ty.clone();
    let words = ty.components.iter().map(|x| x.1 / 4).collect();
    Ok(Place::Element {
        ty,
        binding,
        index: i.regs[0],
        words,
        writable: binding == self.domain && i.regs[0] == self.global_index,
    })
}
```

第一问是下标是否有效：是否属于该数据集允许的域。第二问是是否有权写：即使数字没有越界，也不表示当前实例拥有那个位置。

values[index()+1] 在某些长度下可能合法，但多个实例的访问可能交错，且不再是当前独占元素。编译器不会因为下标仍在范围内，就自动授予普通并行写权限。这正是“范围证明”和“所有权证明”不能混为一谈的原因。

## 8.4 跨函数也不能丢掉位置身份

源码节选：crates/blanguage/src/check/ownership.rs:4，P4 CL13062。

```
#[derive(Clone, Copy, PartialEq, Eq, PartialOrd, Ord)]
pub(super) enum Position {
    Local(usize),
    Element(usize, u32),
    Parameter(usize, usize),
}
impl Place {
    pub(super) fn owned_positions(&self) -> Option<Vec<Position>> {
        match self {
            Self::Indexed { base, .. } => base.owned_positions(),
            Self::ReadOnlyLocal(..) => Some(Vec::new()),
            Self::Local(_, slots) => Some(slots.iter().copied().map(Position::Local).collect()),
            Self::Element { binding, words, .. } => Some(
                words
                    .iter()
                    .map(|word| Position::Element(*binding, *word))
                    .collect(),
            ),
            _ => None,
        }
    }
```

普通函数接收 write/inout 参数时，检查器传递实际位置及字段投影，而不是只记录“它是个 float3”。整个记录与其中一个字段同时独占借用，可能重叠；不同字段则可能互不重叠。Position 与 Place 的比较

帮助保持这个事实。

自己走一遍。 两个变量类型相同，是否证明它们互不重叠？不能。类型说明如何解释数据，身份与偏移才说明是否指向同一处内容。

# 第九章 范围事实：编译器怎样理解 if 的保护作用

## 9.1 条件不只是要生成的跳转

看到 if (i < length(data))，人知道条件成立的分支中 i 小于该长度。编译器也需要保存这种知识，才能判断 data[i] 是否有效。

同样，整数除法要知道除数不为零。这里的知识不是无限强的数学证明器，而是沿当前路径维护的有限事实。

源码节选：crates/blanguage/src/check/bounds.rs:4，P4 CL13062。

```
enum Fact {
    Equal(ValueIdentity, ValueIdentity),
    Index(ValueIdentity, IndexDomain),
    Minimum(ValueIdentity, u32),
    Maximum(ValueIdentity, u32),
    NonZero(ValueIdentity),
}
type Facts = BTreeSet<Fact>;
#[derive(Clone, Default)]
pub(super) struct Proof {
    // 首项是实际来源，其余是当前路径已经证明相等的快照。
    origins: Vec<Vec<ValueIdentity>>,
    condition: Option<Box<Condition>>,
    ranges: Vec<(u32, u32)>,
    nonzero: Vec<bool>,
    domains: Vec<Domains>,
}
```

Fact 包含相等、索引域、最小值、最大值和非零。Proof 还按分量保存来源、范围和条件。float3 的三个分量可能各有不同事实，不能用一项模糊标记替代全部内容。

## 9.2 为什么事实跟随值，而不是永远跟随变量名

设 i=2，在 i<4 的分支中又执行 i=9。先前比较的是旧值二，不是后来写入的九。若把“i 小于四”永久挂在变量名上，就会错误允许新的数组访问。

本版使用值身份和来源快照，并在写入、投影和路径合流时更新事实。这个细节比“给变量加一个安全标签”复杂，却是理解真实编译器分析的关键。

## 9.3 两条路径汇合，什么知识还能保留

若一条分支知道 i∈[0,3]，另一条知道 i∈[0,7]，两条路汇合以后只能共同保证 [0,7]。如果只有一条路径知道除数非零，汇合后也不能无条件保留非零。

源码节选：crates/blanguage/src/check/bounds.rs:60，P4 CL13062。

```
self.nonzero = (0..width)
    .map(|i| self.nonzero.get(i) == Some(&true) && other.nonzero.get(i) == Some(&true))
    .collect();
```

```
self.ranges = (0..width)
    .map(|i| {
        let (a, b) = self.range(i);
        let (c, d) = other.range(i);
        (a.min(c), b.max(d))
    })
    .collect();
self.domains = (0..width)
    .map(|i| {
        self.domains(i)
            .intersection(&other.domains(i))
            .copied()
            .collect()
    })
    .collect();
```

这里对非零取共同条件，对范围取能容纳两条路径的区间。源码中的集合交集同样只保留两侧共同成立的域关系。合流不是把每条路径的最好结论全部相加。

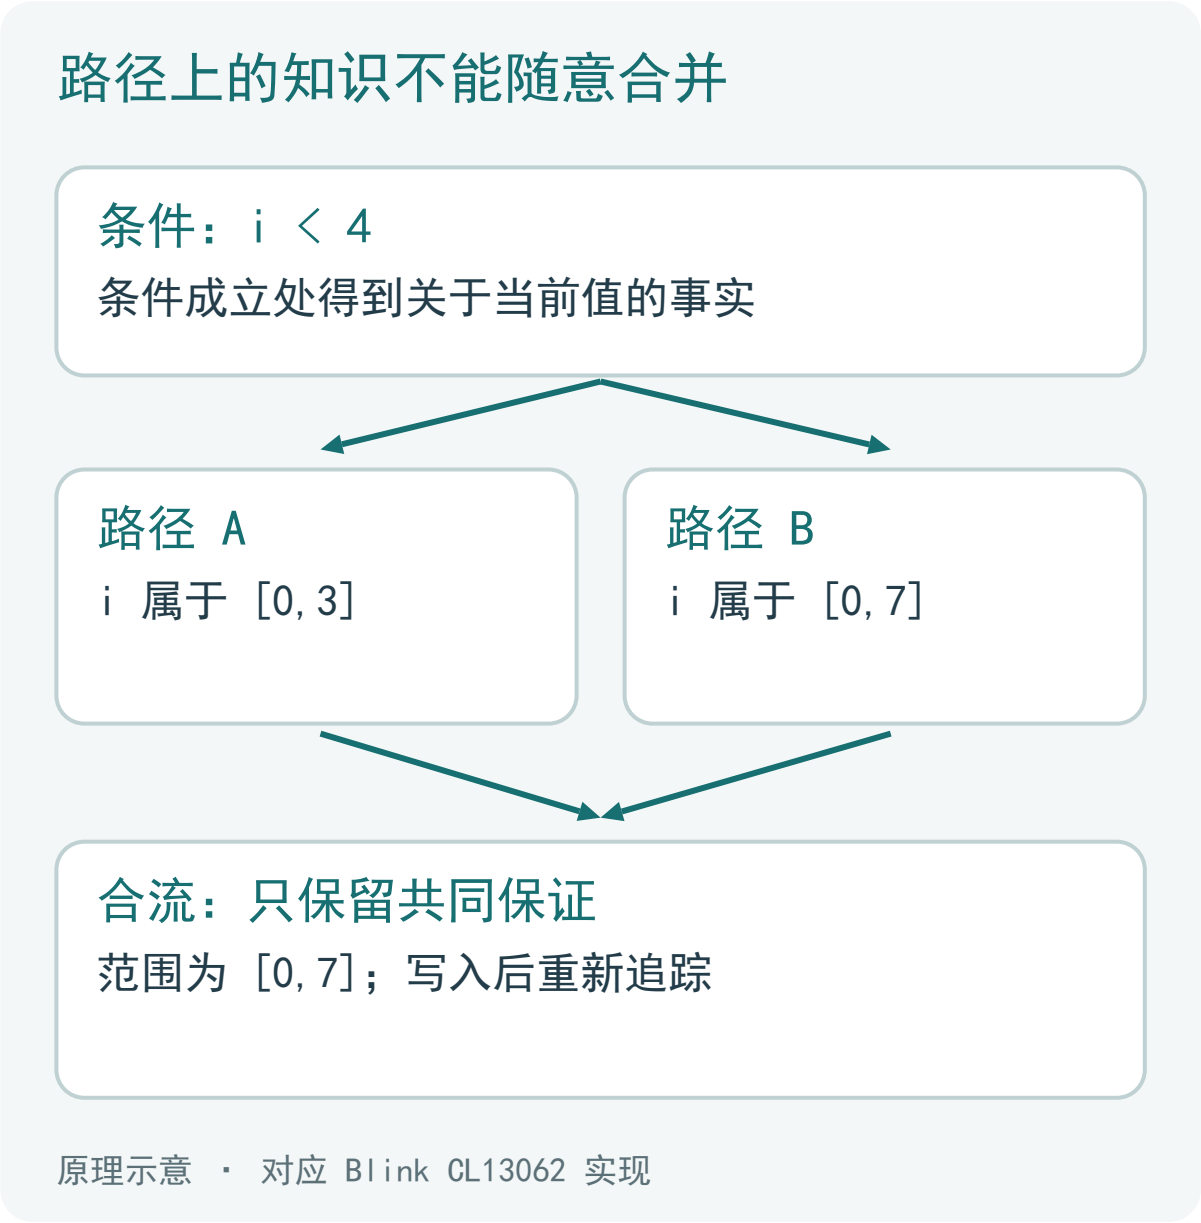



图 9-1：条件内的知识属于该路径和实际值；合流时留下共同事实。重新赋值会产生新的内容身份。

## 9.4 拒绝编译不一定等于程序必然错误

一个复杂算式可能数学上安全，却超出当前分析能力。B137 表示检查器无法静态证明所需的索引关系，不等于它已经找到某次真实越界；反过来，编译成功也不保证业务公式正确或程序必然结束。

自己走一遍。 “编译器知道 i 小于 A 的长度”是否自动允许访问 B[i]？只有还能建立 A、B 的相应长度或域关系时才可以。两个数据集都叫数组，不构成证明。

# 第十章 中间表示：把语言意思和硬件细节分开

## 10.1 为什么需要 IR

若解析完源代码就直接写 x64，GPU 后端便得重新实现一遍类型与并行分析。若直接变成 GPU 风格线程代码，CPU 又会继承不适合自己的细节。

中间表示 IR 保存已经明确的计算：数据布局、阶段、域、读取、写入、标量操作与控制流。前端交付同一份意思，两个后端分别选择硬件表达。

## 10.2 虚拟寄存器只是中间结果编号

手算一项变换可以写成：

```
r0 = 读取当前 value
r1 = 常量 2.0
r2 = r0 × r1
r3 = 常量 1.0
r4 = r2 + r3
把 r4 写回当前 value
```

这是解释用的简化 IR，不是导出文件的逐字内容。r0 等编号让每个结果有明确来源，却还没有决定占用 RAX、XMM0 或栈上的哪一处。把虚拟编号当成物理寄存器，后面就会觉得“怎么会有几百个寄存器”。

源码节选：crates/blanguage/src/ir.rs:574，P4 CL13062。

```
Constant(Reg, Scalar, u32),
Index(Reg),
Uniform(Reg, u32),
LoadLocal(Reg, usize),
StoreLocal(usize, Reg),
```

源码节选：crates/blanguage/src/ir.rs:593，P4 CL13062。

```
Load {
    dst: Reg,
    binding: usize,
    index: Reg,
    word: u32,
},
Store {
    binding: usize,
    index: Reg,
    word: u32,
    value: Reg,
},
Unary {
    dst: Reg,
```

```
    op: UnaryOp,
    a: Reg,
},
Binary {
    dst: Reg,
    op: BinaryOp,
    a: Reg,
    b: Reg,
},
```

Constant 保存位模式，Load/Store 保存实际绑定、下标及 word，Binary 用枚举表达运算。字段已在前端展开，所以一个记录操作可能对应多个标量结果。

## 10.3 Stage 保存执行关系

源码节选：crates/blanguage/src/ir.rs:789，P4 CL13062。

```
#[derive(Clone, Debug)]
pub struct Stage {
    pub domain: usize,
    pub prefix: Option<PrefixCount>,
    pub selection: Option<Selection>,
    pub operation: Operation,
    pub boundary_before: bool,
    pub registers: Vec<Scalar>,
    pub locals: Vec<Scalar>,
    pub code: Vec<Inst>,
    pub reads: Vec<usize>,
    pub writes: Vec<usize>,
    pub cross_access: Vec<usize>,
    pub tiles: Vec<Tile>,
}
```

domain 指向遍历的数据域；prefix 与 selection 限制实际工作；operation 区分普通逐元素、归约、扫描等；reads/writes/cross_access 描述依赖，boundary_before 保留显式阶段边界。

程序还保留源阶段数量和优化后阶段列表。这让我们能观察“源码有两步，执行只需一步”，而不是在应用外再维护一份阶段表。

## 10.4 一次检查怎样完成

check::compile_program 先把参数分类为数据集、纹理、加速结构或统一值，求出布局，建立名字到资源的对应。随后展开程序调用，建立阶段，记录源阶段数，最后运行优化。

源码节选：crates/blanguage/src/check.rs:279，P4 CL13062。

```
    program.prefix_requirements = prefix::relations(&program, &env, d, ContractKind::Requires)?;
    program.prefix_guarantees = prefix::relations(&program, &env, d, ContractKind::Ensures)?;
    let mut facts = prefix::Facts::new(&program.prefix_requirements);
    expand_program(
        world,
        d,
        &env,
        &mut program,
        &mut Vec::new(),
        &mut false,
        &mut facts,
    )?;
    program.source_stages = program.stages.len();
```

```
    crate::optimize::optimize(&mut program);
    Ok(program)
}
```

统一值是整次执行共同使用的参数，不是每个元素各有一份的输出数组。它在 CPU 端作为参数字访问，在 GPU 端进入相应程序参数布局。两者使用同一份 offset，而非各自猜测。

自己走一遍。 改名 value 是否必然改变机器指令？不会。名字主要用于解析和诊断，真正运算由 IR 里的来源、类型和操作表达。

# 第十一章 优化：先理解哪些变化不改变意思

## 11.1 两个独立遍历为什么能合并

seed 写当前元素，scale 立刻使用同一元素。只要不存在跨元素读取、协作或明确阶段边界，就能让实例零连续做自己的两步，再让其他实例做各自两步，不必先写完整中间数组再重新遍历。

普通串行版本原本是两轮循环：

```
第一轮：对所有 i，values[i] = i + 1
第二轮：对所有 i，values[i] = values[i] × 2 + 1
```

合并以后，仍按每个 i 得到相同值：

```
对每个 i：
    value = i + 1
    values[i] = value × 2 + 1
```

这首先是减少数据往返与阶段开销，而不是增加更多线程。

源码节选：crates/blanguage/src/optimize.rs:12，P4 CL13062。

```
if let Some(previous) = stages.last_mut() {
    if matches!(previous.operation, Operation::Map)
        && matches!(stage.operation, Operation::Map)
        && previous.subgroup_operations().is_empty()
        && stage.subgroup_operations().is_empty()
        && !previous.has_tile_scope()
        && !stage.has_tile_scope()
        && previous.domain == stage.domain
        && previous.prefix == stage.prefix
        && previous.selection == stage.selection
        && !stage.boundary_before
        && !cross_dependency(previous, &stage)
        && !cross_dependency(&stage, previous)
    {
        let base = previous.registers.len();
        let local = previous.locals.len();
        map(&mut stage.code, &|r| r + base, &|s| s + local);
        previous.registers.extend(stage.registers);
        previous.locals.extend(stage.locals);
        previous.code.extend(stage.code);
        previous.reads.extend(stage.reads);
        previous.writes.extend(stage.writes);
        previous.cross_access.extend(stage.cross_access);
        previous.reads.sort_unstable();
        previous.reads.dedup();
        previous.writes.sort_unstable();
        previous.writes.dedup();
```

```
        previous.cross_access.sort_unstable();
        previous.cross_access.dedup();
        continue;
    }
}
```

源码明确检查 Map、相同域、相同前缀与筛选条件、没有要求保留的边界、没有跨元素依赖，也排除当前不能这样融合的 subgroup/tile 情况。不能只看到两个 parallel 就无条件合并。

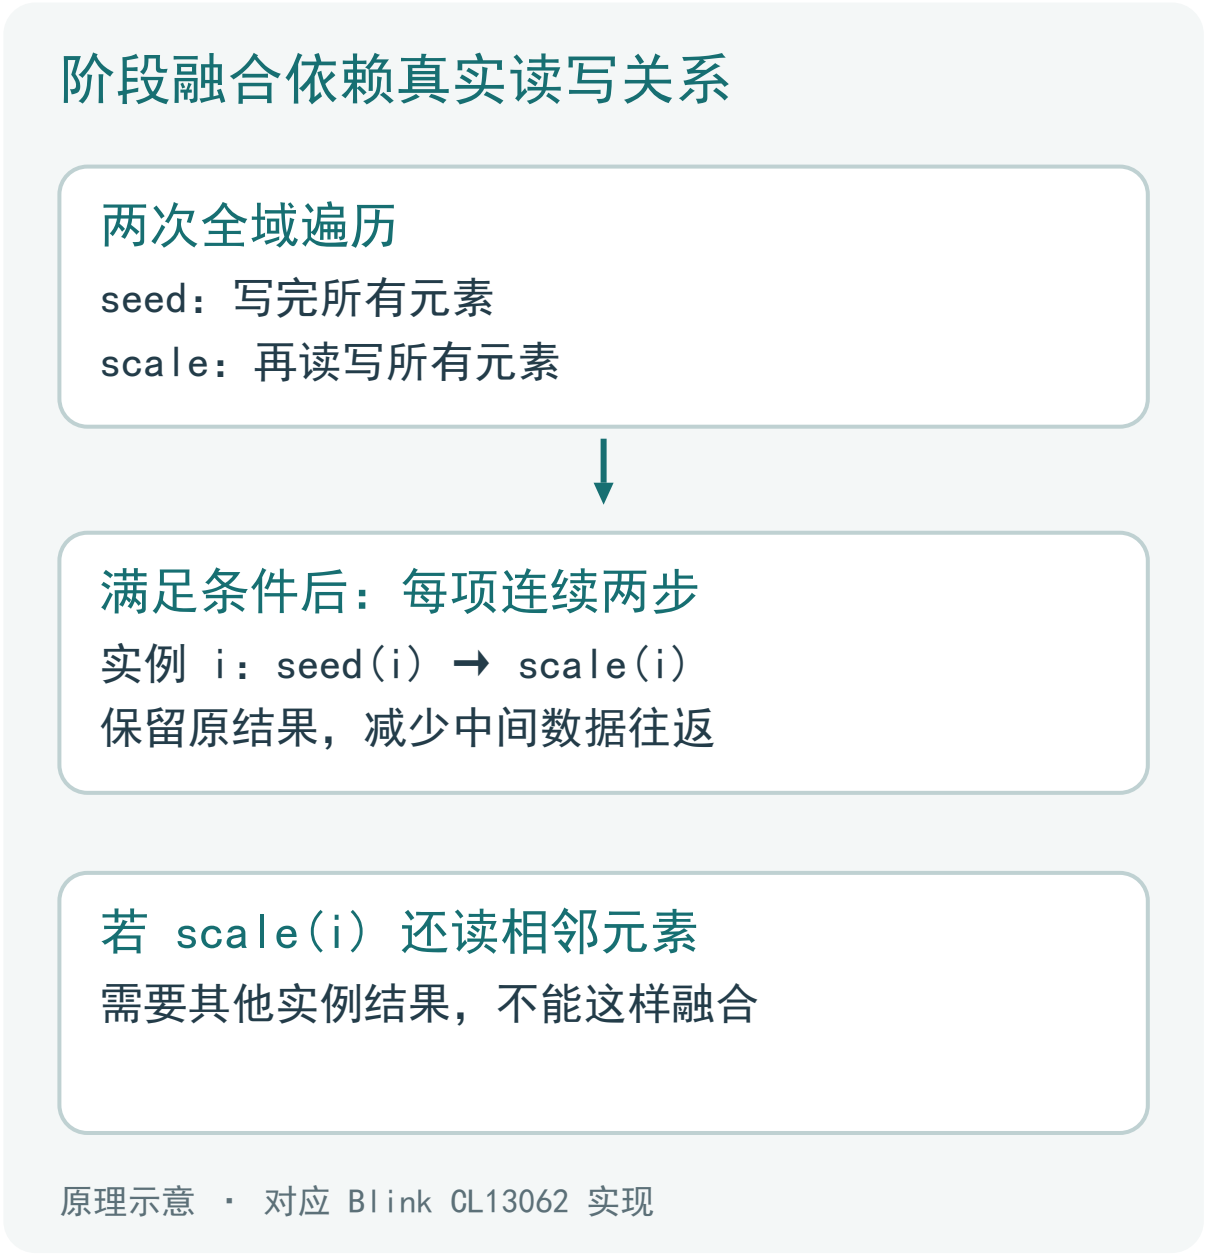



图 11-1：同一元素的前后计算可组成一条流水；若第二阶段需要其他元素的完整结果，就必须保留相应阶段关系。

## 11.2 跨元素依赖为什么改变结论

假设第二阶段读 values[i-1]。如果实例 i 的后半步先执行，而实例 i-1 的前半步还没完成，就会读到旧内容。阶段融合必须关心读取来自哪里，不只关心数组名字是否相同。

源码节选：crates/blanguage/src/optimize.rs:198，P4 CL13062。

```
fn cross_dependency(a: &Stage, b: &Stage) -> bool {
    a.cross_access.iter().any(|r| {
```

```
        (a.writes.contains(r) && (b.reads.contains(r) || b.writes.contains(r)))
            || (a.reads.contains(r) && b.writes.contains(r))
    })
}
```

这段代码把跨元素访问与读写集合结合起来。阶段的关系信息在这里成为优化依据，因此前端漏记一次读取可能不是“少一条日志”，而会导致错误重排。

## 11.3 不再使用的计算怎样删除

若 a=2+3 的结果从不用于输出、控制流或其他可见效果，计算它没有必要。死代码消除从仍需保留的结果与效果反向寻找输入，把没有消费者的纯计算删去。

但写输出、原子更新、append 等效果不能因为返回值无人使用就删除。分支条件也可能控制一次真实写入。dce 不仅看赋值左边是否有人读，还要认识每种指令的效果。

value_flow.rs 处理局部值传播，selection.rs 在可安全表达时简化选择，invariant.rs 处理集合计算中可外提的统一部分。这里没有“只要更短就合法”的规则，必须保持源语言的求值与可见效果。

## 11.4 选择表达式不是总能两边都先算

condition ? a/b : 0 只有选中除法时才应求除法，未选分支可能包含无效访问或不允许提前执行的计算。编译器保留必要控制流，再只对确实安全的操作简化为选择；这与第九章的路径事实相连。

自己走一遍。 “阶段数下降”是否证明整次程序更快？不直接证明。它说明执行结构改变；最终还要看机器码、寄存器压力、访问以及实际测量。

# 第十二章 控制流：条件、循环和返回怎样留下来

## 12.1 顺序指令之外还需要道路

对直线算式，可以从头逐项执行。对 if，需要根据条件走不同道路；对循环，需要回到先前位置；对函数 return，需要离开当前函数的展开范围。

IR 用结构化的 If 和 Loop 保存这些关系：

源码节选：crates/blanguage/src/ir.rs:636，P4 CL13062。

```
If {
    condition: Reg,
    yes: Vec<Inst>,
    no: Vec<Inst>,
},
Loop {
    condition: Vec<Inst>,
    test: Reg,
    body: Vec<Inst>,
},
Break,
Continue,
// 当前静态展开函数的退出域；Exit 只离开最近的 Scope，不结束 invocation。
Scope(Vec<Inst>),
Exit,
```

子指令列表使“这段代码在哪个条件内”仍然清楚。后端再把它变成目标所需的分支、标签与合流结构。

## 12.2 源变量反复赋值与结果编号不冲突

x=x+1 中的新值与旧值不是同一个结果。IR 的虚拟结果可以各有编号，同时使用局部槽表达可变位置。当前实现包含 LoadLocal/StoreLocal 与结构化控制流，不能直接称为已经完成完整 SSA。

SSA 的基本思想是每个结果只定义一次，合流时明确来自哪条路径。理解它有助于读 SPIR-V 和值传播，但不能把课本上一套标准 SSA 算法当成本仓库已经全部实现的事实。

## 12.3 return 不能误杀整个并行实例

普通函数会静态展开进调用者。被调用函数内部 return，只应结束那次函数调用；若把它直接编成整个并行实例退出，调用者后续写结果就会丢失。

因此 IR 还有 Scope/Exit 的局部退出域。CPU 生成器维护退出目标，SPIR-V 的 returns 模块维护对应结构。它们把“退出最近展开函数”与“结束 program 当前实例”区分开来。

自己走一遍。 一个函数返回以后，调用它的函数是否也应直接结束？通常不应。看清当前退出属于哪一层，才能读懂嵌套分支和函数展开。

# 第十三章 CPU 后端之前：认识指令、寄存器和调用约定

## 13.1 CPU 不认识变量名

CPU 取得指令，读取寄存器或内存，做运算，再把结果放回相应位置。value 这个名字不会让处理器自动找到数组。生成器必须把它落实为数据表、记录下标、stride、字段偏移和实际地址。

寄存器是处理器直接使用的小量存储。通用寄存器处理地址、整数和控制信息，XMM 寄存器用于相应标量或 SIMD 运算。内存容量大得多，但地址计算与访问需要成本。编译器因此尽量让仍会使用的中间值留在寄存器。

机器指令由字节编码，例如函数返回指令具有特定编码。汇编是这些编码的可读名称，PE 可执行文件则还要包含操作系统装载所需的结构。生成原生指令不等于已经生成完整应用文件。

## 13.2 函数双方必须对“参数放哪里”达成一致

若调用方把第一个参数放在 RCX，生成函数却从 RDX 读取，指针再正确也会用错。这套约定就是调用约定，属于 ABI 的一部分。

本版 Windows x64 范围入口的四个参数依次是数据指针表、参数 word、结束下标、开始下标。Microsoft x64 ABI 使用 RCX、RDX、R8、R9 传递这四个整数 / 指针参数。这里的顺序在两边必须完全相同。

源码节选：crates/blcompute/src/cpu.rs:28，P4 CL13062。

```
type Entry = unsafe extern "C" fn(*const *mut u32, *const u32, u32, u32);
```

读者可以把它理解为一个 C 函数类型，只是参数中的原始指针由执行框架组织。归约等入口还可能有额外结果参数，不能把所有范围函数都按同一个签名强转。

Microsoft 的 x64 调用约定 说明参数寄存器、栈与保存规则。这里解释的是 Windows x64，不能据此宣称相同字节序列也符合 Linux x64 的调用约定。

## 13.3 栈帧保存临时内容和需要恢复的寄存器

栈是一段按调用组织的内存。生成函数进入时保存需要保持的寄存器，为局部槽与溢出值留出空间；退出时恢复它们，并返回调用者。代码还必须遵守栈对齐和调用其他函数时的约定。

源码节选：crates/blanguage/src/native.rs:79，P4 CL13062。

```
fn leave(&mut self, frame: u32) {
    self.preserve_registers(true);
    if frame > 0 {
        self.bytes(&[0x48, 0x81, 0xc4]);
        self.u32(frame);
    }
    self.bytes(&[0x5b, 0x41, 0x5f, 0x41, 0x5e, 0x41, 0x5d, 0x41, 0x5c, 0xc3]);
}
```

leave 恢复寄存器与栈指针，最后的字节包括返回指令。看懂用途比背下每个十六进制编码更有价值；若要修改编码，必须回到目标指令集与 ABI 逐项核对。

自己走一遍。 一个入口能在本机通过函数指针运行，为什么仍不能直接双击 .x64？裸代码没有普通应用的装载格式、启动入口与链接信息，且依赖执行框架传入的数据和参数。

# 第十四章 寄存器分配与 x64 生成

## 14.1 值的寿命决定能否共用位置

计算 a=b+c; d=a*e; f=d+g 时，a 在得到 d 后可能不再使用；d 在得到 f 后也可能不再使用。若两个值从不需要同时保留，就可以复用同一个物理位置。

反过来，d=a+e 同时需要 a 和 e，它们不能在执行加法之前互相覆盖。活跃性分析就是反向问：“这一点之后，还有谁需要这个值？”

## 14.2 干涉图可以先当作座位冲突图

把每个值画成一个点，同时活跃的两个值连线。相连的点不能使用同一寄存器；不相连的点则有机会共用。把有限寄存器分给这些点，类似给冲突图着色。算法还要考虑不同寄存器类别、调用保存规则和使用频率。

源码节选：crates/blanguage/src/native/allocation.rs:5，P4 CL13062。

```
#[derive(Clone, Copy, Debug, PartialEq, Eq, PartialOrd, Ord)]
pub(super) enum Location {
    Gpr(u8),
    Xmm(u8),
    Stack(u32),
}
```

位置分为通用寄存器、XMM 和栈。放不下的值进入栈槽，这叫溢出；同样不同时使用的溢出值仍可复用栈空间。

源码节选：crates/blanguage/src/native/allocation.rs:48，P4 CL13062。

```
fn edge(&mut self, a: usize, b: usize) {
    if a != b && !self.addressable.contains(&a) && !self.addressable.contains(&b) {
        self.edges[a].insert(b);
        self.edges[b].insert(a);
```

```
    }
}
fn together(&mut self, live: &BTreeSet<PrivateSlot>) {
    for a in live {
        for b in live.range(..a) {
            self.edge(self.id(*a), self.id(*b));
        }
    }
}
```

edge 记录冲突，together 将同一时刻活跃的值关联起来。实际实现还处理条件、循环、调用和可寻址局部，不能把这两段短代码当作完整分配器。

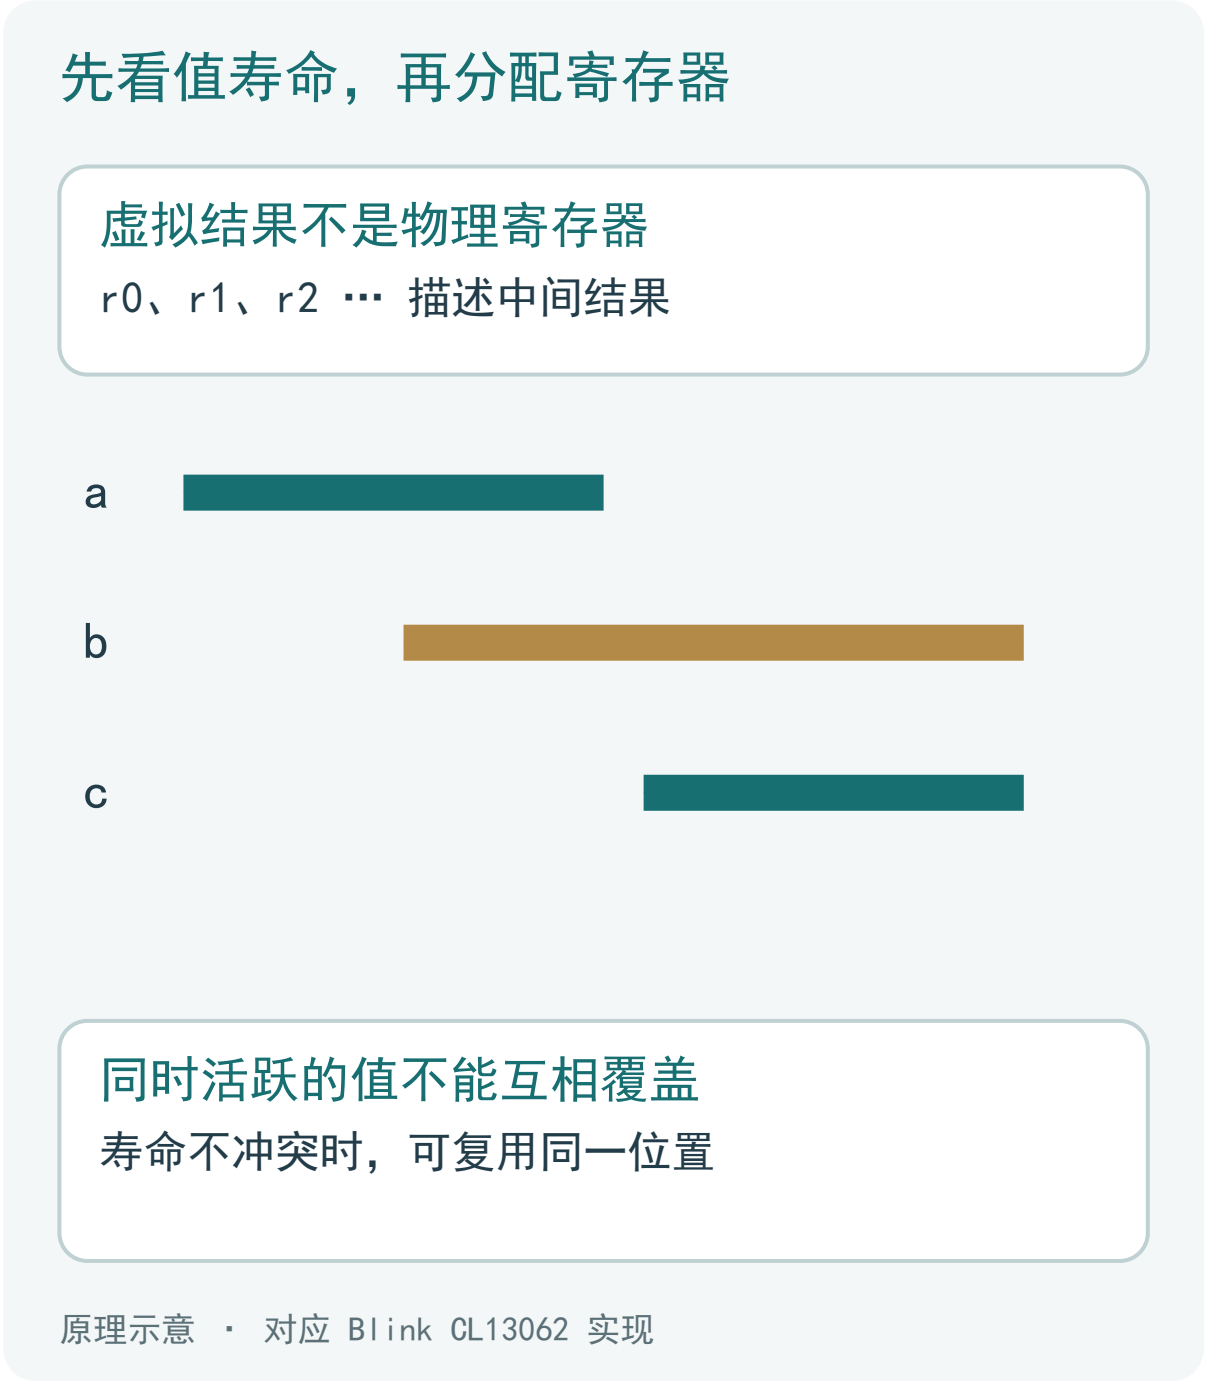



图 14-1：虚拟编号很多，物理寄存器有限。只有寿命不冲突、类别和调用规则也允许的值，才可以复用位置。

## 14.3 Emitter 把结果写成真实字节

源码节选：crates/blanguage/src/native.rs:93，P4 CL13062。

```
fn jump(&mut self, condition: Option<u8>) -> usize {
    if let Some(c) = condition {
        self.bytes(&[0x0f, c]);
    } else {
        self.bytes(&[0xe9]);
    }
    let at = self.code.len();
    self.u32(0);
    at
}
fn patch(&mut self, at: usize, target: usize) {
    let relative = (target as i64 - (at + 4) as i64) as i32;
    self.code[at..at + 4].copy_from_slice(&relative.to_le_bytes());
}
```

一个前向跳转生成时，目标代码可能尚未出现。生成器先写占位位移，记住位置；目标出现后，patch 按“目标地址减去该跳转后续位置”补入相对位移。它不是运行时搜索标签。

算术、加载、存储和转换也都进入 Emitter。operands.rs 选择可直接使用的操作数，integer.rs 处理整数专门降低，texture.rs 将 CPU 纹理访问连接到对应实现。不能只读 emit 入口就认为已读完全部指令生成。

## 14.4 重定位解决外部地址

Sin、Cos 等运算可能调用执行框架提供的原生辅助函数。生成时保存重定位位置与辅助函数类别，装载代码时再填入本进程中的真实地址。机器码字节与这张重定位清单共同构成 NativeCode。

源码节选：crates/blanguage/src/native.rs:27，P4 CL13062。

```
#[derive(Clone, Debug)]
pub struct Relocation {
    pub offset: usize,
    pub intrinsic: NativeIntrinsic,
}
#[derive(Clone, Copy, Debug)]
pub enum NativeIntrinsic {
    Sin,
    Cos,
    Floor,
    Exp,
    Exp2,
    Log,
    Log2,
    Pow,
}
#[derive(Clone, Debug)]
pub struct NativeCode {
    pub bytes: Vec<u8>,
    pub relocations: Vec<Relocation>,
    pub stack_bytes: u32,
}
```

这也解释了为什么单独复制裸指令字节不一定就能运行：其中的调用地址、参数表与寿命仍有上下文。

自己走一遍。 更多融合是否总能降低寄存器占用？不一定。融合可能延长值的同时活跃区间，导致溢出。减少阶段与减少寄存器压力有时需要权衡。

# 第十五章 CPU 执行：范围并行与 SIMD 是两层事情

## 15.1 先把工作分成范围

一百万个元素不意味着创建一百万个操作系统线程。运行时把连续元素组成范围，每个工作者领取一段，用本机范围函数处理。

源码节选：crates/blcompute/src/cpu.rs:74，P4 CL13062。

```
loop {
    let begin = work.next.fetch_add(work.grain, Ordering::Relaxed);
    if begin >= work.count {
        break;
    }
    let end = (begin + work.grain).min(work.count);
```

fetch_add(grain) 原子地领取下一个起点，末尾用 min 保证最后范围不超过 count。线程数与领取顺序会变化，但每个范围中的当前元素仍有自己的独占位置。

这里的 Relaxed 只用于领取不重叠的编号。它不是宣称所有数据访问都无需顺序约束；任务发布、工作完成与存储寿命由线程池调用和相应拥有者负责。不能把一个原子变量的内存序泛化为整个算法的同步规范。

## 15.2 SIMD 让一个核心同时处理多个元素

多个线程使用多个核心；SIMD 则让一个核心的一条适当指令对多个分量工作。两者可以叠加：每个工作者领取连续范围，范围内再以四个元素组成 SSE2 批次。

本版 native/packet.rs 为能够表达的直线计算建立四元素计划。主循环先处理完整批次，余下元素由同一程序语义的标量部分完成。一个长度为十的范围，可以先做两批四，再处理剩下二。

源码节选：crates/blanguage/src/native.rs:586，P4 CL13062。

```
let stage = &lowered;
let mut graph = allocation::Graph::new(stage);
let allocation = Allocation::new(stage, &graph);
let packet = packet::Plan::new(program, stage).map(|plan| {
    let allocation = PacketAllocation::new(stage, &mut graph, &plan.address_only);
    (plan, allocation)
});
drop(graph);
let frame_layout = Frame::new(
    &allocation,
    packet.as_ref().map(|(_, allocation)| allocation),
);
```

这里同时建立普通分配与可用的 packet 计划。复杂控制流、部分协作或无法这样降低的操作有其实际实现范围，书中不能把所有 B 指令都描述为已经四路 SIMD。




图 15-1：范围负责把工作交给多个工作者，SIMD 负责范围内的批量运算，尾部仍保持相同计算含义。图中的两个范围和四元素批次用于说明，不是固定线程数。

## 15.3 机器码怎样变成可调用函数

源码节选：crates/blcompute/src/cpu.rs:141，P4 CL13062。

```
    let address = unsafe { VirtualAlloc(std::ptr::null_mut(), code.bytes.len(), 0x3000, 0x04) };
    if address.is_null() {
        return Err(std::io::Error::last_os_error().into());
    }
    let out = Self { address };
    unsafe {
        std::ptr::copy_nonoverlapping(code.bytes.as_ptr(), address.cast(), code.bytes.len());
        let mut old = 0;
        if VirtualProtect(address, code.bytes.len(), 0x20, &mut old) == 0 {
            return Err(std::io::Error::last_os_error().into());
        }
```

```
        if FlushInstructionCache(GetCurrentProcess(), address, code.bytes.len()) == 0 {
            return Err(std::io::Error::last_os_error().into());
        }
    }
    Ok(out)
}
```

执行框架分配可写内存，复制指令、处理必要重定位，再把页面改成可执行并刷新指令缓存。CPU 随后通过匹配 ABI 的入口调用这些指令，而不是由 Rust 对每一条 B 指令逐项解释。

可写和可执行内存、页面权限与函数签名属于这段代码必须满足的真实平台要求。它们与“变量是否乘二”处在不同层次。

## 15.4 如何理解性能

并行效率常受调度成本、内存带宽、缓存命中、寄存器压力和算法规模共同影响。小到四个元素时，创建或准备执行的成本会淹没算术，不能用它衡量吞吐。大规模逐元素任务又可能先达到内存带宽上限，此时再加核心也不会按倍数增长。

本书的四元素运行只用于源码追踪；需要性能比较时，应使用第一本书已提供的 Release、大规模同算法对照，同时分清编译、准备、内核执行与数据传输。源码结构能解释测量，不能代替测量。

自己走一遍。 一条 SIMD 指令处理四项，是否一定比标量快四倍？不是。加载、存储、依赖、尾部、转换与实际指令吞吐仍会限制速度。

# 第十六章 GPU 之前：线程、工作组、subgroup 和分歧

## 16.1 一个 parallel 实例如何找到自己的元素

GPU 把大量实例组织成工作组。每个实例有本组编号和组内编号，组合后得到逻辑上的全局位置。二维、三维调度还需按布局展开，不能永远假定只存在 X 维。

为了直观，先看一维示意：组宽四，组二的组内一对应 $2\times4+1=9$。这只是公式示意；本版很多集合管线实际使用六十四线程工作组，具体宽度由对应操作与程序要求决定。

## 16.2 尾部实例为什么还要判断是否有效

要处理十项而组宽四，需要三个组，共十二个实例。最后两个位置没有真实元素，不能直接读取。普通 map 的无效实例可以不做正文；有协作屏障时，则还要考虑全组参与条件，不能让一部分实例提前退出，使其他实例永远等不到它们。




图 16-1：工作组组织逻辑实例，不承诺所有组同时驻留。尾部、共享内存与协作条件都必须在生成代码中落实。

## 16.3 工作组与 subgroup 不是一个东西

工作组是程序声明的协作范围。subgroup 是设备在组内安排的一批执行通道，可支持 ballot、广播和归约等操作。不能把工作组宽度、subgroup 宽度或某张显卡的常见 wave 宽度当作同一个常数。

多个通道根据不同条件走不同路径，称为分歧。它不表示程序自动错误，却可能使硬件分批执行不同路径；需要 subgroup 协作时，还必须满足相应的参与和能力约定。

## 16.4 内存层次影响算法结构

每个实例有自己的值，组内有可共享的存储，所有组再通过设备全局存储交换数据。组内共享不能直接当作所有工作组共同可见的数组；跨组数据依赖一般要经过全局存储和恰当的后续命令依赖。

因此归约和扫描通常有多个设备阶段：组内先解决局部问题，再处理各组摘要，最后把摘要传播回去。这不是 API 给算法增加的无意义步骤，而是硬件协作范围在算法中的体现。

自己走一遍。 两个工作组都在运行，能否用本组 barrier 等待另一组？不能。组内屏障不提供全局会合；假定所有组同时驻留还可能造成等待无法推进。

# 第十七章 SPIR-V：直接生成 GPU 能接受的程序

## 17.1 SPIR-V 位于哪里

SPIR-V 是标准二进制中间语言。它仍由驱动处理成设备执行形式，不是某一种 GPU 的最终机器指令。Blink 自己把 IR 写成 SPIR-V，不先生成 GLSL/HLSL 再调用另一编译器。

标准规定模块、类型、结果编号、存储类别、控制流与能力。详见 Khronos SPIR-V 规范。理解“它是有类型和结构的程序”，比把 .spv 当作一团不透明字节更有帮助。

## 17.2 一条指令怎样装进 word

源码节选：crates/blanguage/src/spirv.rs:41，P4 CL13062。

```
fn op(out: &mut Vec<u32>, code: u16, args: &[u32]) {
    out.push(((args.len() as u32 + 1) << 16) | code as u32);
    out.extend_from_slice(args);
}
```

每个 word 是三十二位。首 word 的高十六位保存本条指令总 word 数，低十六位保存操作码，其余 word 保存操作数。若有三个操作数，总长度是四，首 word 就由 (4<<16)|opcode 组成。

例如一个浮点加法在概念上要说明结果类型、结果编号和两个输入编号。后端从 IR 的类型与结果关系生成这些编号，不能把 CPU 的 XMM 编号直接塞进 SPIR-V。

以本实现用到的 OpFAdd 为例，操作码是一百二十九，操作数是“结果类型、结果编号、输入 A、输入 B”，共四个，所以整条指令占五个 word，首 word 为 0x00050081。下面的 % 名称只是便于阅读的符号，文件里实际存放整数编号：

```
word 0: 5 << 16 | 129
word 1: f32 的类型编号
word 2: 新结果的编号
word 3: 输入 A 的编号
word 4: 输入 B 的编号
```

这五项把“浮点加法”完整连接起来。若类型编号错了，即使操作码正确，指令仍然不是有效的同一项计算。

## 17.3 为什么生成器维护多个输出区

模块中的类型、常量、装饰和函数体有各自的位置。Emitter 使用 types、constants、defs、decorations 和 body 等集合，逐步建立结果，再按格式组成模块。

相同类型和常量可以复用对应编号；不同结果需要各自编号。分支要有正确的块、标签与合流关系，不只是把一串算术操作按顺序拼起来。

## 17.4 一个语言阶段可能需要多个 GPU pass

源码节选：crates/blanguage/src/spirv.rs:19，P4 CL13062。

```
pub enum Pass {
    Main,
    ReductionTail,
    ScanTail,
    ScanAdd,
    ScanRootAdd,
    CompactScatter,
    SelectionArguments,
    SelectionScan,
    SelectionScatter,
    SortHistogram(u32),
    SortScatter(u32),
    SortKey(usize),
    SortScan,
    SortGather,
    DispatchArguments(PrefixCount),
}
```

Pass 包含主执行、归约尾部、扫描补加、筛选散布和排序各步骤。语言给用户一个完整集合操作，后端则依据算法生成多份相互配合的 SPIR-V。这与 CPU 的范围内核和尾部处理是同一思想：保留统一语言含义，分别选择硬件实现。

自己走一遍。 生成 .spv 成功是否就说明数据已经算过？没有。它只说明相应代码已生成；还要创建设备资源、管线与命令，提交并实际完成。

# 第十八章 Vulkan 执行：从代码到真正提交

## 18.1 四个对象先分开

设备代表可执行工作的 GPU 与队列。缓冲保存数据。计算管线连接 SPIR-V 与必要布局。命令缓冲记录“绑定什么、调度多少、哪些访问需要依赖”。这些对象各有寿命，不能把所有句柄都当作无归属整数。

描述符告诉程序如何找到实际资源；程序参数说明本次长度、分区起点及统一值。编译时的 binding 零最终必须对应这次绑定的实际缓冲，而非另一个恰好大小相同的对象。

## 18.2 编译程序和执行一次是两回事

同一份已编译 GPU 程序可以消费多次不同数据，不必每次重新创建管线。一次执行需要的临时扫描空间、描述符和命令则属于这次执行。把两类资源混在一起，会导致重复创建或寿命不清。

GpuProgram 持有编译结果与管线；提交路径建立本次数据关系与命令，最后返回 Submission。

源码节选：crates/blcompute/src/vulkan/mod.rs:1714，P4 CL13062。

```
pub fn submit(
    &self,
    data: impl Into<Bindings<DomainBindings<GpuDataset>>>,
    values: &[Value],
```

```
) -> Result<Submission> {
    self.submit_steps(data, values, NonZeroU32::MIN)
}
```

submit 接收拥有的数据绑定。返回不是最终结果数组，而是尚可能在设备中运行的提交对象。

## 18.3 源码阶段怎样变成命令

submit_owned 遍历 IR 阶段，根据 Operation 选择 map、扫描、筛选、排序或归约的记录函数。静态域从已知容量安排调度，有效前缀域则使用设备中的计数与间接参数。

命令通常包括绑定管线、绑定资源、写入本次参数、发起 dispatch，以及前后操作所需的内存依赖。CPU 不再替每个像素或粒子执行 B 算式，只负责准备这份设备工作。

## 18.4 同一个 API 不代表所有设备能力都一样

普通计算、subgroup、硬件求交和窗口呈现有不同能力需求。框架按程序需要申请能力；没有窗口的计算任务不应被迫拥有交换链。读 Device::for_programs、能力收集与设备创建时，要看申请来自哪个实际消费者。

自己走一遍。 把同一份 SPIR-V 用在另一设备上，为什么仍可能失败？设备必须支持程序要求的能力、布局和资源限制，标准代码格式不等于所有硬件功能相同。

# 第十九章 GPU 数据：分页、传输与只读 view

## 19.1 一份逻辑数组可以分成多块物理存储

当数据很大，单块分配会受到真实设备资源和分配条件约束。Blink 保留一份逻辑记录域，将数据存放到多个物理页，用页表保存各页的设备地址。

源码节选：crates/blanguage/src/spirv.rs:38，P4 CL13062。

```
/// GPU 存储页的最大字节数；每页只容纳完整记录，页表使用 64 位设备地址。
pub const PAGE_BYTES: u32 = 256 * 1024 * 1024;
```

当前页上限是 256 MiB，这是实现参数，不是语言规定“数组只能这么大”。每页只容纳完整记录。若 stride 为四十字节，页容量取整除；不能让一条记录前半在这一页、后半在下一页，却仍按单页地址读取。

```
每页记录数 = floor(页字节上限 / stride)
页号 = 元素下标 / 每页记录数
页内下标 = 元素下标 % 每页记录数
字段地址 = 页表[页号] + 页内下标 × stride + 字段偏移
```




图 19-1：逻辑下标连续，物理页不必连续。页表与数据页由同一实际存储所有者持有，地址计算来自统一类型布局。

## 19.2 上传和下载是实际的数据移动

CPU 内存与 GPU 设备存储不是把同一地址重新命名就能互换。上传准备数据并通过传输命令写入设备；下载把实际设备结果带回可供 CPU 访问的存储，还要等待相应完成与可见性。

因此程序只需继续在 GPU 消费结果时，保持驻留往往更合理；只有需要 CPU 数值、保存文件或其他真实消费者时才读回。少做一次传输，与把计算本身优化一倍，是不同类型的收益。

## 19.3 view 保存的是来源关系

一个记录可以引用某份冻结的只读数据，用于共享模型、材质或几何。view 不是把整份被引用数据嵌入每条记录，也不能把 CPU 地址原样当成设备地址。

前端知道字段类型与访问权限，传输框架遍历真实来源关系，为目标侧构造相应地址信息，并让来源存储继续活着。嵌套 view 的传输因此是闭合资源图的处理，不只是一段裸字节复制。

源码节选：crates/blcompute/src/vulkan/mod.rs:841，P4 CL13062。

```
#[derive(Clone)]
pub struct ReadDataset(Rc<GpuDataset>);
pub type ViewBinding<'a> = crate::ViewBinding<'a, ReadDataset>;
```

ReadDataset 在这里共享冻结来源。当前版本通过 view 消费的路径与后来可能补齐的直接 read 绑定能力应分别看待，不因数据只读就假定所有绑定入口都已经支持。

自己走一遍。 冻结以后原数据是否从此无人拥有？不是。可写所有权转成只读共享，实际消费者通过引用关系继续持有它；最后一个消费者结束以后才具备释放条件。

# 第二十章 同步：先后顺序、可见性与完成信号

## 20.1 顺序正确，还要保证看到正确内容

第一段计算写数组，第二段读取它。我们需要第二段在所需写入之后执行，并能看到这些写入。仅把两条 dispatch 按顺序记录，不足以代替所有内存依赖。

同步中至少分清三个问题：哪些执行必须先后发生，哪些写入要对后续读取可见，以及 CPU 在什么时候能确认设备工作结束。它们不是同一个开关。

## 20.2 RAW、WAR、WAW 可以先用中文理解

先写后读：读者要消费前一段的新值。先读后写：写者不能过早覆盖前一读者仍需的数据。先写后写：后一次覆盖要遵守约定顺序。只有实际涉及同一资源、同一相关访问时才建立相应依赖。

IR 的 reads/writes 是这类关系的重要来源，执行框架再结合传输与计算访问生成 Vulkan 依赖。Khronos 的 同步示例 区分执行依赖和内存可见性；本书把原则对应到当前项目所用 API，不把其他版本示例原样当作 Blink 源码。

## 20.3 barrier 与 fence 分别回答什么

命令中的 barrier 处理相应设备访问之间的依赖；fence 让 CPU 查询或等待一次提交是否结束。fence 不是每个元素使用的锁，也不替代程序内部的所有数据依赖。

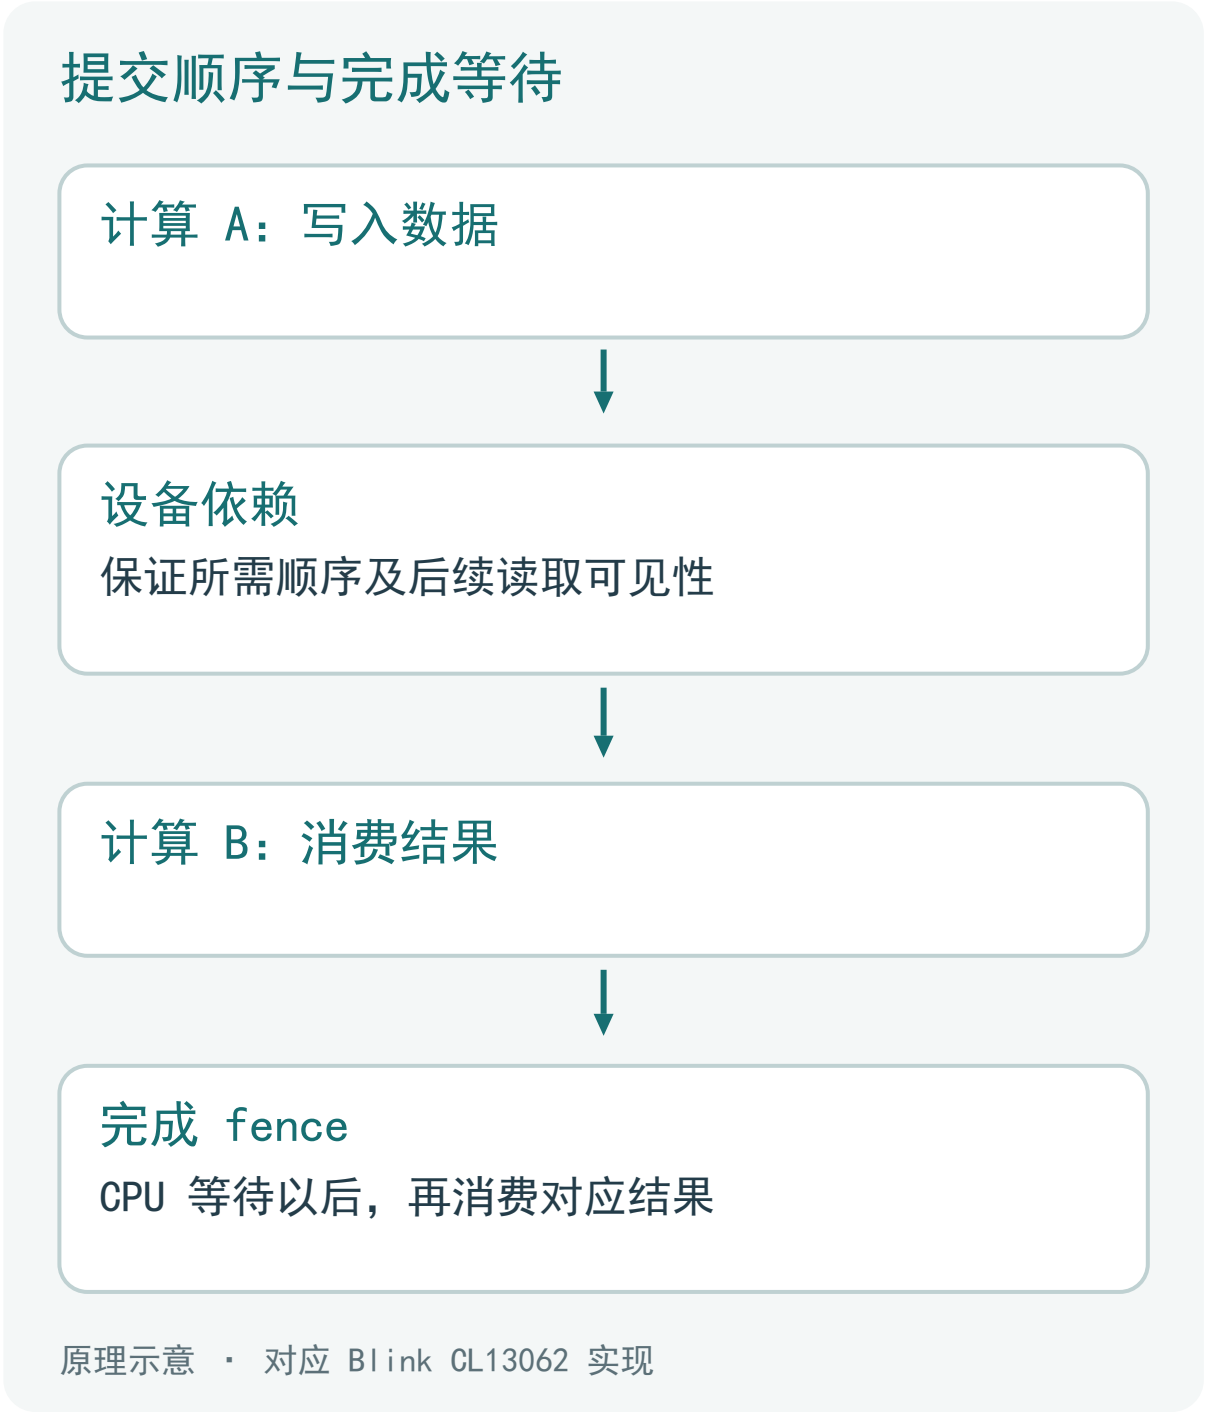



图 20-1：A 写、B 读之间需要正确的设备依赖；CPU 取回结果需要真实完成。GPU 组内 barrier 只负责自己的协作范围，与这两者也不同。

## 20.4 为什么不在每一步之间等待 CPU

若所有中间结果都先读回 CPU 再上传，设备流水会不断断开。submit_after 与 submit_join 接续实际所有权和前序提交，使后续工作继续消费设备结果。

源码节选：crates/blcompute/src/vulkan/mod.rs:1744，P4 CL13062。

```
/// 同队列直接衔接，order 索引前项所有数据以及 additional 中依次追加的数据。
pub fn submit_after(
    &self,
    previous: Submission,
    order: &[usize],
    additional: impl Into<Bindings<DomainBindings<GpuDataset>>>,
```

```
    values: &[Value],
) -> Result<Submission> {
    self.submit_join([previous], order, additional, values)
}
```

本版主要是同一设备队列上的衔接，不等于多队列、多个 GPU 或所有分支都真正同时执行。接口表达可交接的关系，实际硬件并发还取决于实现与设备安排。

自己走一遍。 CPU 收到 submit 返回值后能否立即把所有输入显存释放？不能。返回表示提交路径建立，不表示 GPU 已经不再访问它们。

# 第二十一章 资源寿命：Drop 为什么还不够

## 21.1 CPU 变量消失与 GPU 使用结束不是同一时刻

```
CPU: 提交 A → 创建 B → 旧变量退出作用域
GPU:      A 仍在执行 → B 才开始读取
```

如果旧变量析构时立刻释放设备内存，GPU 会继续访问已经失去所有者的地址。解决办法必须围绕真实最后使用点，不能只围绕 CPU 帧号或经验上“应该已经结束”。

## 21.2 物理存储和最后使用点一起保存

源码节选：crates/blcompute/src/vulkan/mod.rs:807，P4 CL13062。

```
pub struct GpuDataset {
    storage: ManuallyDrop<GpuStorage>,
    last_use: Option<Rc<Execution>>,
}
/// 不透明物理存储；可读借用不允许交换存储与它的执行寿命。
#[doc(hidden)]
pub struct GpuStorage {
    // allocation 是只读页表；数据页与它一起随唯一存储转移。
    allocation: Allocation,
    pages: Vec<Allocation>,
    ty: Ty,
    stride: u32,
    count: u32,
    producer: Usage,
    views: Views<ReadDataset>,
    instances: Option<ray::InstanceInput>,
}
```

GpuDataset 保存实际 GpuStorage 和可选 last_use。GpuStorage 持有页表、数据页、类型、容量、只读来源及相关实例资源。它们不是多份数组副本，而是同一物理存储的组成。

源码节选：crates/blcompute/src/vulkan/mod.rs:830，P4 CL13062。

```
impl Drop for GpuDataset {
    fn drop(&mut self) {
        // Rust 唯一析构入口移交一次物理存储；外层不再重复释放页和依赖。
        let storage = unsafe { ManuallyDrop::take(&mut self.storage) };
        if let Some(execution) = &self.last_use {
            execution.discard(storage);
        } else {
            drop(storage);
        }
    }
```

```
}
```

析构把存储交给最后执行点处理；没有未决使用时直接释放。ManuallyDrop 在这里让唯一析构入口显式移交一次存储，避免外层再自动释放同一内容。理解这份所有权转移后，才适合修改 unsafe 部分。

## 21.3 Completion 记录设备事实

源码节选：crates/blcompute/src/vulkan/execution.rs:5，P4 CL13062。

```
pub(super) struct Completion {
    pub inner: Rc<Inner>,
    pub fence: Cell<VkFence>,
    pub submitted: Cell<bool>,
    pub sequence: Cell<u64>,
    result: Cell<Option<i32>>,
}
```

Completion 持有 fence 与提交状态。wait 调用 Vulkan 等待并保留真实结果，Execution 在完成后释放该次命令资源和不再使用的存储。共享多个引用不会制造多个设备完成事实，它们指向同一个完成点。

## 21.4 wait 以后交还什么

源码节选：crates/blcompute/src/vulkan/mod.rs:2475，P4 CL13062。

```
    pub fn wait(mut self) -> Result<Completed> {
        self.execution.wait()?;
        let timings = match &self.queries {
            Some(queries) => queries.read()?,
            None => GpuTimings {
                elapsed_ms: 0.0,
                stage_ms: Vec::new(),
            },
        };
        for dataset in &mut self.bindings.datasets {
            dataset.last_use = None;
        }
        Ok(Completed {
            bindings: self.bindings,
            accelerations: self.accelerations,
            timings,
        })
    }
}
```

Submission 的 wait 先等待真实执行，取得时间查询结果，再交还 Completed。数据的未决使用标记在这里清除。后续可以继续交接设备数据，也可以读回 CPU，不强迫每次等待都下载全部结果。

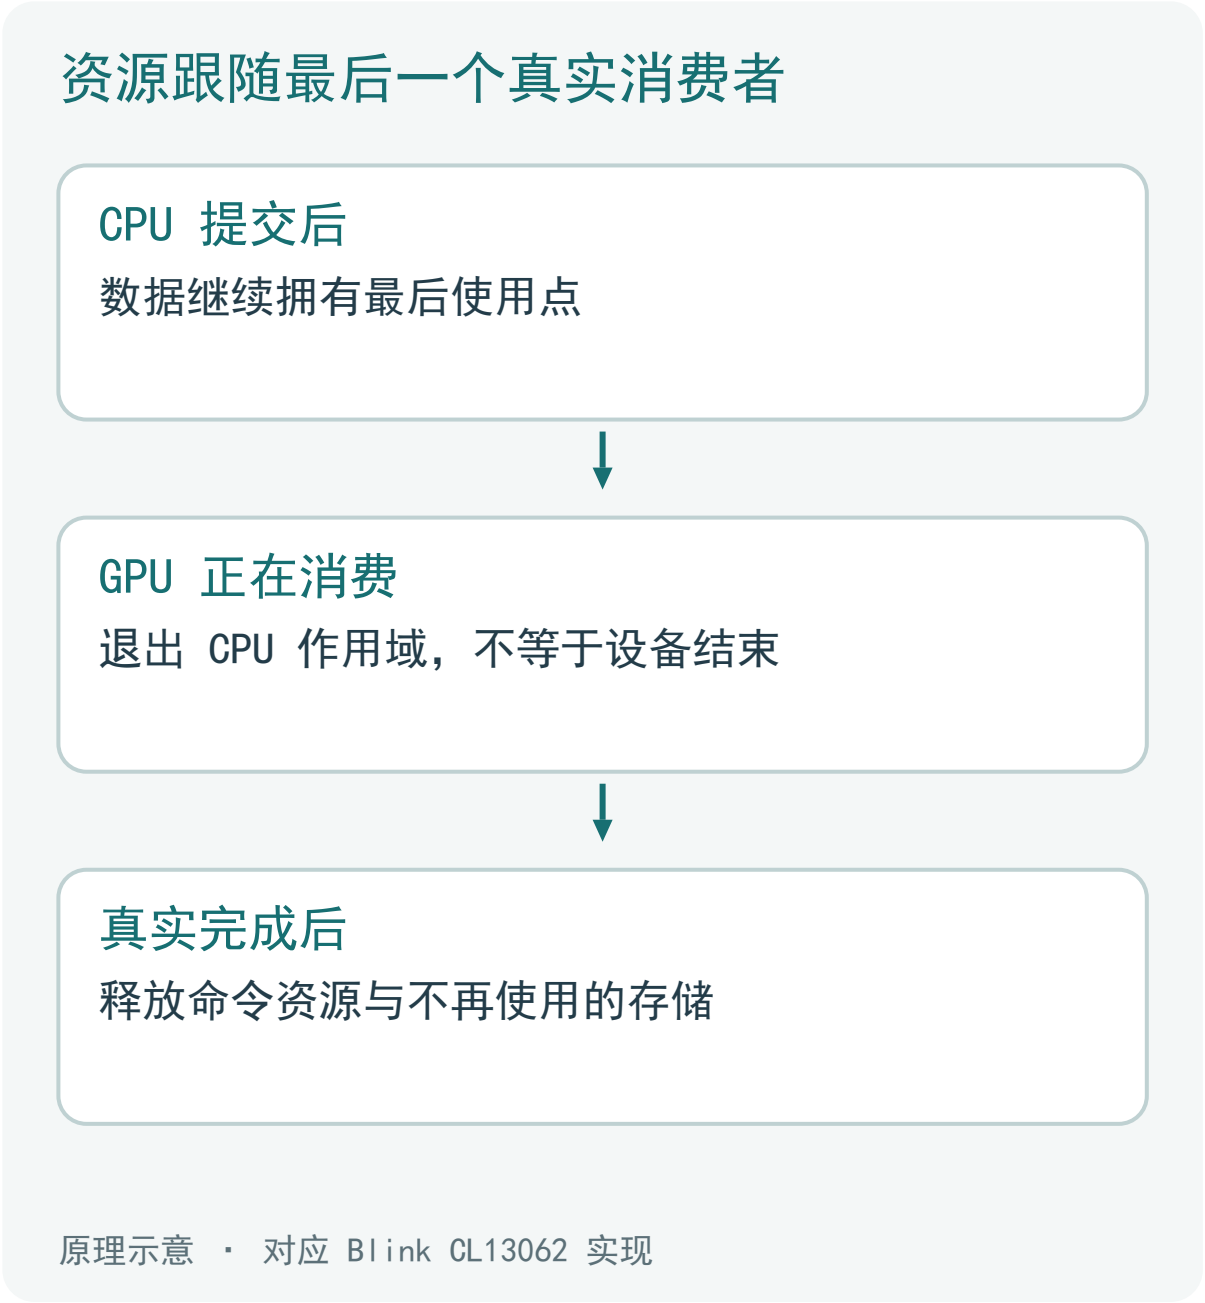



图 21-1：资源沿真实消费者保留。共享和分支共享执行事实，物理存储在最后相关使用结束以后释放。

自己走一遍。 只看到引用计数归零，能否证明 GPU 已结束？不能。还要看计数所拥有的对象是否承接实际未完成提交；本实现正通过 last_use、Execution 和 Completion 建立这个关系。

# 第二十二章 归约：从顺序累加到一棵合并树

## 22.1 先看八个数的工作量

顺序求和把八项一个接一个累加，主要链长随项数增长。并行树先合并相邻对，再合并各对的结果，最后得到总和：八项、四项、两项、一项。

总工作量仍然与项数同阶；变化的是可以同时进行的部分，以及最深依赖链。不是因为加法忽然免费，而是把一条长链分成能并行的短链。

用四项 [2,3,1,4] 手算：第一层可以同时得到 2+3=5 和 1+4=5，第二层再得 5+5=10。三次加法分成两层，而非沿一个累计值连续等待三次。真实 GPU 实现用六十四路树；示意树说明并行原理，不保证浮点组合顺序

与任何串行循环一致。

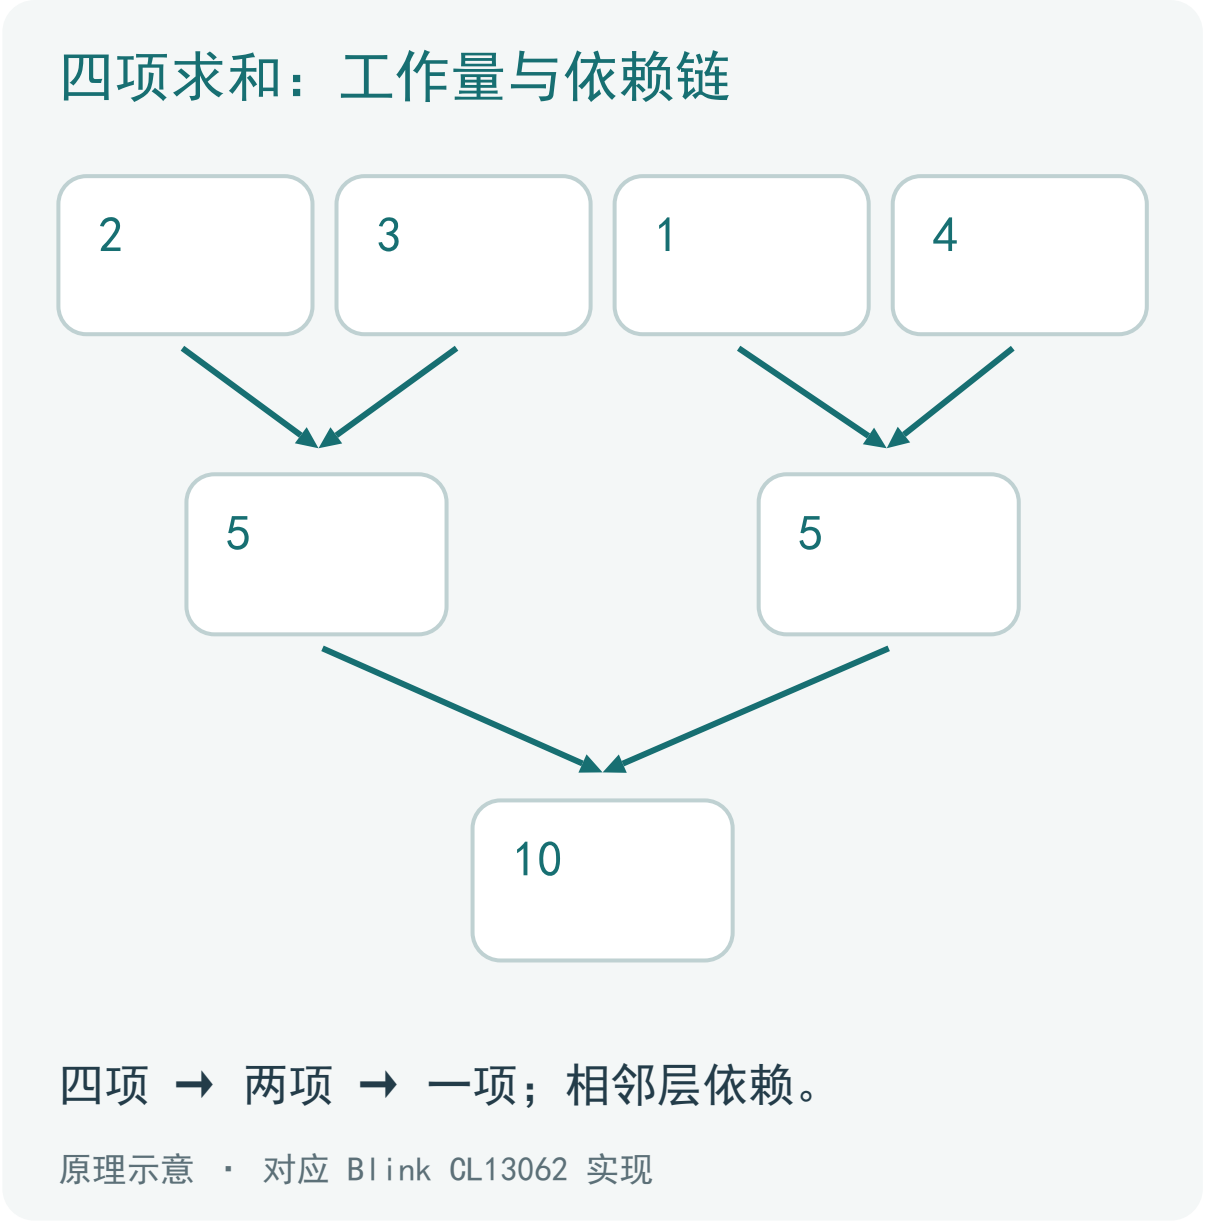



图 22-2：工作量和依赖深度是两个不同指标。增加并行硬件能缩短可并行部分，无法消除最后一层对前一层结果的依赖。




图 22-1：归约产生摘要；扫描产生每项之前的摘要；筛选借助扫描给保留项分配互不冲突的位置。

## 22.2 GPU 先合并组内，再合并组间

spirv/reduce.rs 让组内线程先装入自己的值或单位元，沿共享存储的树合并。末尾不足一组的无效项放入单位元，例如加法的零，避免改变结果。

浮点 min/max 还要处理实际有效长度和比较语义，不能只塞入一个哨兵就假定 NaN、正负零等所有情况都正确。源码中的有效项选择正是这类细节；手算普通加法时可以先用零理解尾部。

源码节选：crates/blanguage/src/spirv/reduce.rs:112，P4 CL13062。

```
self.scan_barrier();
for width in [32, 16, 8, 4, 2, 1] {
    let width = self.constant(Scalar::U32, width);
    let selected = self.id();
    self.emit(176, &[b, selected, local, width]);
    let run = self.id();
    let end = self.id();
    self.emit(247, &[end, 0]);
    self.emit(250, &[selected, run, end]);
    self.emit(248, &[run]);
```

```
    let other = self.id();
    self.emit(128, &[u, other, local, width]);
```

执行框架把各组摘要继续交给下一轮归约，而非读回 CPU 自己累加。

源码节选：crates/blcompute/src/vulkan/mod.rs:2254，P4 CL13062。

```
let mut length = count;
let mut pass = 0;
loop {
    let groups = length.div_ceil(64).max(1);
    if pass > 0 {
        commands.barrier(0x800, 0x800, 0x40, 0x60);
    }
```

实际行数在每层减少，组数按向上取整计算。只有一个组时写最终目标，否则写当前执行拥有的临时摘要。这里的多 pass 来自算法层次。

## 22.3 结合律、顺序与浮点误差

整数无溢出的数学加法具有结合律；固定宽度整数则还要按语言的实际溢出语义理解。浮点数由于舍入，(a+b)+c 与 a+(b+c) 可能不同，所以树形浮点求和不能许诺与串行逐项求和逐位一致。

自定义归约也要说明组合规则、单位元与顺序要求。矩阵乘法、字符串拼接等可能不满足交换律，但满足适当结合条件时仍能按顺序组合。不能把“可结合”与“可以任意重排元素”画等号。

## 22.4 CPU 使用范围摘要

CPU 对各领取范围生成原生计算，得到部分结果，再按该操作要求合并摘要。它与 GPU 共享语言含义，却无需模仿 GPU 的每个六十四线程 barrier。阅读 native/reduce.rs、custom_reduce.rs 与 cpu.rs，要跟踪摘要的布局和顺序。

自己走一遍。 求最小值时，尾部空位填零可以吗？一般不可以。若所有真实值都为正，零会错误成为最小值。必须使用该运算与类型定义的单位元及边界语义。

# 第二十三章 扫描、筛选与有效前缀

## 23.1 扫描比求和多保存了什么

输入 [2,3,1,4] 的独占加法扫描是 [0,2,5,6]。第 i 项保存它之前所有项的和，不包含自己。总和为十，但扫描保存的是每个位置之前的累计关系。

顺序代码维护一个 running 值即可；并行实现先形成组内树，再让各组获得之前各组的摘要，最后把组前缀加回本组结果。本版 GPU 使用 work-efficient Blelloch 扫描，CPU 使用对应范围摘要与补加。

先看四项扫描的两次树遍历。上行先求局部摘要：[2,3,1,4] → [2,5,1,10]。此时根保存总和十，但我们要的是每一项之前的和。把根改成单位元零，得到 [2,5,1,0]。

下行时，左子树收到父节点原有前缀，右子树收到“父节点前缀＋左子树总和”。根层处理后是 [2,0,1,5]；两个底层对子再同时处理，得到 [0,2,5,6]。这就把一个总摘要展开为每个位置自己的前缀。




图 23-1：上行计算摘要，下行传播前缀。图中数组状态只是说明四项算法，实际代码还要处理多分量、尾部、组间摘要与设备存储。

四项时，上行和下行各有三次树节点处理。对大规模数据，处理量仍随项数线性增长，树的深度随规模的对数增长。这是 work-efficient 的含义；它不声称小输入也必然值得启动 GPU。

源码节选：crates/blanguage/src/spirv/scan.rs:17，P4 CL13062。

```
pub(super) fn scan_barrier(&mut self) {
    let scope = self.constant(Scalar::U32, 2);
    let semantics = self.constant(Scalar::U32, 0x108);
    self.emit(224, &[scope, scope, semantics]);
}
```

这个 barrier 是组内共享树的同步。跨组递归由外层设备命令组织，它不能被一个组内 barrier 替代。

## 23.2 稳定筛选怎样避免争抢输出下标

假设保留标记是 [1,0,1,1]，独占扫描得到 [0,1,1,2]。保留项使用自己的扫描结果作为输出位置：原第零、二、三项分别写到零、一、二。

这样既保持输入顺序，也为每个保留项产生唯一位置。无需让所有线程每写一项都争抢同一个全局计数器。这是扫描从数学操作变成存储分配方法的例子。

## 23.3 容量与有效长度为什么要分开

输出缓冲能容纳一百万条，不表示本次真的写了一百万条。筛选以后可能只有二十万条有效记录。后续程序应消费有效前缀，尾部容量仍存在，却不是算法结果。

IR 的 PrefixCount 与 PrefixRelation 将数据和计数的对应保存下来。DomainBindings 继续持有这些关系。一个任意 u32 数字并不能自动证明另一缓冲的前多少条有效。

## 23.4 GPU 已知的数量不必马上告诉 CPU

设备筛选产生 Count，后续间接调度从该 Count 生成工作组数量。若每次都先把 Count 读回 CPU 再下发下一阶段，就打断了本可留在设备中的数据关系。

vulkan/prefix.rs 组织这些参数与层级工作，bindings.rs 保留实际资源身份和前缀关系。修改 Count 或重新映射绑定时，要更新相应关系，不能让旧关系继续替新内容背书。

## 23.5 where 与 compact 不相同

where 选择原位置，正文仍拥有原记录身份；compact 把保留项稳定移动到新的连续前缀。后者的输出下标一般不再等于原下标。当前 GPU where 可使用私有原索引辅助，CPU 则在原范围收集选中位置，语言层仍保留原位置含义。

自己走一遍。 一百万容量的缓冲在本次筛选后 Count 为零，后续是否可以把全部容量当作有效输入？不可以。容量满足存储，Count 及其关系表达本次有效结果，两者职责不同。

# 第二十四章 稳定排序：为什么先搬索引，最后才搬记录

## 24.1 稳定性不只关乎“排好大小”

有三个记录，键分别为二、一、二；两个键为二的记录在输入中先后出现。稳定排序要求输出中仍保持它们的原相对顺序。只比较最终键是否递增，无法判断这一点。

本版 GPU 使用四位一轮的 LSD 基数排序，每轮有十六个桶。先统计各桶数量，再计算桶起点和局部位次，最后稳定散布。处理三十二位键需要按各四位组逐轮推进。

## 24.2 每轮只搬小的键和原序号

若一条记录很大，每轮排序都搬全部字段会增加大量内存流量。实现中间主要重排八字节的“键与原始序号”，等完整顺序确定后，再 gather 一次完整记录。

源码节选：crates/blanguage/src/spirv/sort.rs:65，P4 CL13062。

```
e.sort_store(s.target, e.index, 2, 0, key);
e.sort_store(s.target, e.index, 2, 1, original);
```

对于多个字段的字典序键，先处理低优先级，再稳定处理高优先级；每次装入下一键时通过当前原序号读取原记录。这使已有排序结果保留下来，而不额外复制一份完整键记录。

## 24.3 有符号数与浮点数怎样成为可排序编码

无符号整数的编码顺序直接对应大小。带符号整数要处理符号位，浮点数还要分别处理正负编码。此版本以位映射形成所定义的全序，原字段内容不修改。

源码节选：crates/blanguage/src/spirv/sort.rs:49，P4 CL13062。

```
let key = match key_type {
    SortKey::U32 => key,
    SortKey::I32 | SortKey::F32 => {
        let sign = e.constant(Scalar::U32, 0x8000_0000);
        let mask = if key_type == SortKey::F32 {
            let shift = e.constant(Scalar::U32, 31);
            let negative = e.sort_binary(194, key, shift);
            let zero = e.constant(Scalar::U32, 0);
            let inverse = e.sort_binary(130, zero, negative);
            e.sort_binary(197, inverse, sign)
        } else {
            sign
        };
        e.sort_binary(198, key, mask)
    }
};
```

这不等于随意用浮点 < 就能得到相同顺序：正负零、NaN 编码等在这里有明确处理方式。阅读排序结果时，应先看接口承诺的键顺序，而不是只凭平常数值比较猜测。

## 24.4 稳定逻辑次序不能依赖硬件偶然安排

subgroup 的 lane 与 LocalInvocationIndex 未必能按某张显卡的习惯直接等同。实现合成算法所需的逻辑序号，声明必要 subgroup 能力，保证散布的稳定含义。把碰巧在一台机器成立的映射写进算法，会破坏跨设备正确性。

CPU 排序则使用自己的原生范围与合并路径，位于 native/sort.rs 和 cpu/sort.rs。两个后端的代码形态可以不同，稳定性、键解释和记录布局必须服从同一语言操作。

自己走一遍。 数据量很大时，只优化比较指令是否足够？未必。排序常受读写、直方图、散布、摘要扫描及中间记录大小影响，减少不必要搬运同样重要。

# 第二十五章 块内协作、原子与有界输出

## 25.1 tile 先提供一份明确的输入快照

邻域或小块算法经常需要同一组读取一块数据。若直接让每个实例随意共享写，很难推断谁看到了哪一步。tile 将输入形状、有效长度和读取关系明确表达；publish 再交付阶段中生成的不可变中间值。

前端位于 check/tile.rs 和 check/subgroup.rs，共享布局和操作由 IR 保存；CPU 的 native/tile.rs 与 GPU 的 spirv/tile.rs 分别落实。CPU 不会为了模仿每个 GPU lane 再创建一个系统线程，它可以在一个

范围内顺序模拟相应块内步骤，保持同样的语言结果。

## 25.2 barrier 不是随意插入的一次暂停

若一半实例进入包含 barrier 的分支，另一半不进入，协作可能无法完成。语言检查因此必须知道块内协作发生在什么执行结构中，普通函数不能偷偷藏一个要求所有实例会合的屏障。

静态根块、输入快照、发布和实际最后读取位置共同决定共享存储的安排。后端可以复用不再被消费的共享 word，但不能因为进入了下一行代码就覆盖上一阶段仍会读取的内容。

## 25.3 原子操作也有不同含义

atomic add 解决单次更新的不可分割性。acquire/release 等内存序还涉及相关访问何时可被观察，它们不是“更快 / 更慢”的随意等级。dataset 的跨实例原子与 tile 内部原子由同一操作表达，但实际作用域与存储类别不同。

CPU dataset 原子需要真实跨线程原子指令；一个范围独占的 tile 私有存储则有自己的执行方式。GPU 根据目标选择 Device 或 Workgroup 范围。后端要落实语义，而不是把所有原子都机械翻译成同一个调用。

## 25.4 append 为什么返回是否接纳

输出容量有限，不能让全局计数无限增长后再假定每条记录都写入成功。封闭的 append 先在容量内预留唯一位置，再完整写入记录，并用 bool 告诉调用者是否接纳。

CPU 使用容量比较与原子比较交换等原生操作；GPU 将实际活动 subgroup 的预留合并，减少争用。阶段完成后才交付有效前缀，预留计数本身不能被当作同阶段所有记录都已写完的发布信号。

这里的容量、所有权和发布属于数据协议的核心。具体返回顺序与跨后端成功调用者未必一致，因此不能把 append 误写成稳定 compact。

自己走一遍。 得到一个唯一输出下标，是否已经证明该位置的记录写完并对所有消费者可见？没有。预留、写入、发布与消费是不同步骤。

# 第二十六章 DLL 与跨语言调用：边界怎样保持清楚

## 26.1 C、C++ 和 Rust 为什么能调用同一份 B

跨语言调用需要稳定约定：函数叫什么，参数怎样传递，数据怎样布局，错误怎样返回，谁分配和释放。C ABI 是当前 DLL 的共同边界，不把普通 Rust Vec 或 C++ 对象的内部结构直接当跨语言协议。

blc build-dll 生成 DLL、导入库、.abi.h 与 Rust 包装器。C++ 使用相应资源管理类，Rust 使用切片、Result 和 Drop，两者消费同一份 B 接口与布局；Rust 原生 crate 路径也继续保留。

## 26.2 DLL 内究竟装了什么

源码节选：crates/blanguage/src/dll/mod.rs:203，P4 CL13062。

```
/// 构建一个具体、无前置条件的入口；输出 DLL、import lib、.abi.h、.rs。
/// B 前端在此处完成检查；DLL 内嵌已检查的 IR，create 准备原生机器码 / GPU pipeline。
/// Rust 工具链只负责既有 Rust 执行框架、导出 ABI 与 PE 链接，不编译 B 算法。
```

```
pub fn build(program: &ExecutableProgram, output: &Path) -> Result<()> {
    if !cfg!(all(target_os = "windows", target_arch = "x86_64")) {
        return Err("build-dll 当前输出 Windows x64 DLL".into());
    }
```

此版本把已检查 IR 内嵌到 DLL，在 create 时准备 CPU 原生代码或 Vulkan 管线。Rust 工具链负责执行框架、ABI 导出与 PE 链接，不负责替 B 算法生成 x64/SPIR-V。

因此消费 DLL 不需要重新提供 B 源码，但第一次创建仍有准备成本。描述部署、启动时间和单次计算性能时，应分别记录这些事实。

## 26.3 错误与寿命不能跨边界含糊处理

宿主数组在调用期间保持有效，可写区间不能与其他借用冲突。当前 DLL 的 run 同步完成本次工作，复制结果后返回，handle 由配套 destroy 释放。不能在函数返回后继续偷偷借用宿主栈上的数组。

同样，C++ 异常或 Rust 内部错误不应未经约定穿过 C ABI。具体导出、错误文本和安全包装见 blcompute/ffi.rs、dll/header.h.in、binding.rs.in 与 library.rs.in。阅读这组文件时，应把每个创建与销毁函数配成对。

## 26.4 反向调用与独立应用是另两项能力

“C++ 能调用 B DLL”不代表 B 已能直接导入任意 C++ 类或 Rust 函数；“B 能生成算法库”也不代表已具备完整应用入口。这些能力分别涉及语言接口、链接和应用运行模型，应按实际实现分别理解。

自己走一遍。 为什么生成头文件比手写一个“看起来一样”的结构更可靠？它取自同一编译布局，避免 bool 宽度、向量对齐和字段偏移在两个工程里各自猜测。

# 第二十七章 纹理、求交与显示：通用执行框架的边缘在哪里

## 27.1 纹理不只是二维数组下标

纹理读取包括维度、层级、格式、采样与过滤。CPU 和 GPU 使用相应实现，语言端通过明确资源接口表达需求。texture.rs 处理数据与层级，Vulkan 纹理模块负责实际图像、视图与上传寿命，后端负责把相关 IR 变成各自的读取。

看纹理源码时先辨认：源像素数据属于谁，上传何时完成，采样器与视图何时销毁，B 程序实际请求的是 fetch 还是采样。它们影响结果与成本，不能都概括成“查一张表”。

## 27.2 硬件求交是通用能力，材质算法属于引擎

BLAS 描述底层几何加速结构，TLAS 组织实例。Vulkan ray 模块创建与拥有实际结构，B 的 RayQuery IR 表达查询及所需结果。只有消费真实顶点或变换时，相关读取才有对应需求。

通用框架负责结构与物理资源寿命；BLEngine 的材质、光照和光传输算法留在引擎。这样，语言工程不会因为第一个消费者是引擎，就把某种材质或场景状态写进通用编译器。

## 27.3 窗口呈现也有自己的资源关系

vulkan/present.rs 管理交换链、图像与呈现状态；它不拥有编辑器排版或文档。计算程序无需窗口时，普通设备不必创建交换链。理解实际消费者，是阅读这些平台模块的入口。

这一章提供源码位置和职责定位。完整 BVH 数学、光传输与引擎场景组织另见《BLEngine 源码分析》，本书集中在语言如何表达并执行这些能力。

自己走一遍。 某个 B program 能查询三角形，是否说明语言工程应拥有完整场景树？不说明。通用查询资源与应用场景语义是不同职责。

# 第二十八章 把完整路径重新连起来

## 28.1 再看最初的一行代码

value = value * 2.0 + 1.0 进入 lexer 后成为 token；parser 按优先级组成树；World 提供 value 的来源与类型；检查器把当前位置落实为独占元素，并建立对应指令与阶段。

优化器利用同域和访问关系融合 seed/scale，传播可复用的局部结果，删除无消费者的纯计算。CPU 后端分配寄存器、生成范围函数和可用 SIMD 批次，线程池领取范围；GPU 后端生成结构化 SPIR-V，Vulkan 绑定实际页表、参数与管线，记录并提交工作。

最后，CPU 在真实完成后获得结果，GPU 资源沿最后使用点释放。整个过程里，类型布局和资源身份始终从各自的真实所有者传向消费者，没有让每层再猜一份答案。

## 28.2 修改一种能力，应该沿哪些文件阅读

若要扩展一种算术，先确定源语义、类型与边界，再找表达式检查、IR 运算、优化可见效果、CPU/SPIR-V 降低及必要运行设施。不是看到 GPU 缺一个 opcode，就先在 shader 拼一段特殊代码。

若要增加集合操作，还要确定域、输出容量、计数、稳定性、顺序和临时数据寿命。若要增加平台，则不仅是增加几条指令，还包括 ABI、启动、代码装载、线程、内存、文件和链接。

这些是阅读与设计问题，不是在每次修改后增加一套固定审核系统。验证应复用正式编译和实际原生执行，记录真实输入、输出与必要测量。

## 28.3 编译成功、执行正确和性能优秀分别证明什么

编译成功说明当前前端与后端接受并生成相应结果。原生执行的数值核对说明特定输入下得到了已观察结果。性能记录说明某个构建、设备和规模的成本。任一项都不能单独替代其他两项。

一张图展示 dispatch，不证明所有设备都支持；某次 CPU/GPU 结果相同，不证明浮点算法对所有输入逐位等价；一项阶段优化，也不能直接冒充完整应用加速。

## 28.4 下一次读源码，可以从这里开始

先选一段真实程序，写清输入、输出和允许的关系；沿 compile_entry → load → lexer/parser → check → optimize → native/spirv → cpu/vulkan 前进。每一层都问：它拿到什么，补充了什么知识，交出去什么对象，这个对象由谁拥有、何时结束。

当这些问题都能回答，目录就不再是一堆文件名。你看到的是一个能解释自己如何工作的系统：语言表达计算，编译器保留含义，后端选择实现，执行框架让资源与真实工作共同完成生命周期。

# 附录 A 构建产物和运行结果的读取

## A.1 从干净构建得到工具

工程根目录执行 `cargo build --workspace --release`，生成 `target/release/blc.exe` 和 `blrun.exe`。本书记录来自 CL13062 的独立 Release 构建，避免混入工作区其他线程未提交代码。普通读者直接使用工程正式目录即可，不需要复制本书研发目录。

## A.2 读取四个浮点结果

BLDATA 包含文件头和记录载荷，不是文本。若只想查看第一章生成的四项值，可在项目根目录执行下面这条 Python 命令。它是查看二进制的工具命令，不是 B 应用的打印语法。

```
python -c "import struct; from pathlib import Path; p=Path('Saved/MapCpu/values.bldata'); print(struct.unpack('<4f'
  ,p.read_bytes()[24:]))"

(3.0, 5.0, 7.0, 9.0)
```

文件头结构以 `Dataset::read_data/write_data` 为准。不要让某个临时脚本对格式的猜测成为第二份正式布局。

## A.3 编译导出文件读什么

`.x64` 是 CPU 原生阶段字节，配套重定位说明辅助函数地址的装载位置；`.spv` 是对应 GPU pass，布局文件说明绑定、类型和参数。不同操作会生成不同数量的 pass。不要按“源函数一个，文件一定一个”推断。

本次实际导出：

| 文件 | 字节数 |
| --- | --- |
| lessons_map_demo.0.reloc | 0 |
| lessons_map_demo.0.spv | 1856 |
| lessons_map_demo.0.x64 | 495 |
| lessons_map_demo.layout | 261 |

# 附录 B 按职责查找源码

下表是阅读索引，路径相对于工程根目录。完整精确文件列表和哈希另存于 `compiler/源码版本索引.json`。

| 源码位置 | 主要阅读问题 |
| --- | --- |
| crates/blanguage/src/main.rs | 命令行怎样选择检查、代码导出与 DLL 输出 |
| lib.rs | 怎样装载模块、核对接口、选择具体入口并形成 Compilation |

| 源码位置 | 主要阅读问题 |
| --- | --- |
| lexer.rs、parser.rs、ast.rs | 原文怎样变成 token、树与可定位诊断 |
| generics.rs、value_parameters.rs、type_sets.rs | 具体类型、静态值与类型集合怎样形成实例 |
| check.rs | 参数、资源、函数、表达式与 parallel 怎样形成 IR |
| check/ownership.rs、view.rs | 位置身份、字段借用与只读来源怎样传递 |
| check/bounds.rs、flow.rs、returns.rs | 条件、写入和合流怎样影响事实与控制流 |
| check/prefix.rs、各集合操作文件 | 有效域、容量、类型与输出关系怎样检查 |
| check/tile.rs、subgroup.rs、atomic.rs、append.rs | 协作、共享与接纳怎样保持语言含义 |
| ir.rs、ir/* | 布局、指令、阶段、集合操作和能力怎样共同表示 |
| optimize.rs、optimize/* | 哪些阶段可以融合，哪些值与效果必须保留 |
| native.rs、native/operands.rs、integer.rs | 怎样选操作数、编码指令和处理跳转 |
| native/allocation.rs、packet/* | 活跃性、寄存器、栈槽与四元素 SIMD 怎样落实 |
| native/reduce.rs、scan.rs、compact.rs、sort.rs | CPU 集合内核与范围摘要怎样生成 |
| spirv.rs、spirv/* | 类型、结果编号、控制流、协作与多 pass 怎样编码 |
| dll/mod.rs、source.rs、*.in | 检查结果怎样嵌入库，三种语言接口怎样生成 |
| crates/blcompute/src/lib.rs、bindings.rs | 数据、参数与有效域关系怎样由实际对象持有 |
| cpu.rs、cpu/sort.rs | 机器码怎样装载，范围任务与集合尾部怎样执行 |
| views.rs、texture.rs | 只读引用图与纹理内容怎样组织 |
| vulkan/mod.rs、raw.rs | 设备、资源、管线、绑定与实际 API 声明在哪里 |
| vulkan/execution.rs | 完成点、命令资源和未决存储何时释放 |
| vulkan/transfer.rs | 物理传输与只读来源怎样闭合 |
| vulkan/prefix.rs、各集合操作文件 | 设备计数、间接参数与临时摘要怎样衔接 |
| vulkan/texture.rs、ray.rs、present.rs | 图像、加速结构和交换链怎样分别拥有资源 |
| ffi.rs | DLL 边界的数据转换、执行、错误与释放 |
| main.rs | 现有 blrun 怎样准备输入、运行并写 BLDATA |

# 附录 C 底层知识与对应章节

| 知识 | 从哪里开始 | 对应源码 |
| --- | --- | --- |
| 字节、位模式、地址、对齐 | 第二章 | ir::Ty、Dataset、页寻址 |
| 所有权、引用计数、析构 | 第三章、第二十一章 | Rc、GpuDataset、Execution |
| 深度优先装载与依赖环 | 第四章 | lib::load |
| token、语法树、运算优先级 | 第五、六章 | lexer、parser |
| 静态实例化与数据布局 | 第七章 | generics、Ty |
| 数据竞争、独占位置 | 第八章 | ownership、Place |
| 路径事实、区间、合流 | 第九章 | bounds、flow |
| IR、控制流与 SSA 思想 | 第十至十二章 | Inst、Stage、局部槽 |
| ABI、栈、寄存器和重定位 | 第十三、十四章 | native、allocation、Executable |
| 多核、SIMD、带宽与调度 | 第十五章 | execute_ranges、packet |
| 组、subgroup、分歧与共享内存 | 第十六章 | tile、subgroup、SPIR-V |
| 二进制指令格式与结果编号 | 第十七章 | spirv::op、Emitter |
| 管线、描述符、命令和队列 | 第十八章 | GpuProgram、submit_owned |
| 分页、传输与引用图 | 第十九章 | GpuStorage、transfer、view |
| 执行依赖、可见性、fence | 第二十、二十一章 | barrier、Completion |
| 结合律、树、前缀与稳定性 | 第二十二至二十四章 | reduce、scan、compact、sort |
| 原子、发布与有界接纳 | 第二十五章 | atomic、append、tile |
| C ABI、库与宿主边界 | 第二十六章 | dll、ffi |

# 附录 D 版本与进一步阅读

本书源码版本为 P4 CL13062，工作日期为 2026-10-26。后续语言会继续发展；阅读新版源码时，以实际接口为准。书中页大小、组宽、向量化范围与当前平台都是该版本事实，不升格为语言永久限制。

- Blink 开源工程：源码、学习资料与正式 PDF。
- 语言规则：语法、类型、访问和集合操作的正式说明。
- 架构说明：编译器与执行框架的职责和所有权。
- 问题与实现状态：现有能力、原生运行记录与未完成事项。
- Microsoft x64 调用约定：参数、寄存器与栈规则。
- Khronos SPIR-V 规范：二进制格式、类型、控制流和执行环境。
- Khronos Vulkan 同步示例：执行依赖与内存可见性的典型关系。

- Rust Arc：原子引用计数与共享所有权；实际单线程 GPU 对象所用 Rc 需区别理解。